


Y4377241

中国科学技术信息研究所

硕士学位论文

融合上下文信息的科技文献标题的机器翻译

Research on Machine Translation for Titles of Scientific Papers
with Contextual Information

作者 郭姝澳

导师 董诚

何彦青

中国科学技术信息研究所

论文提交日期（2023年10月）



独创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，论文中除已经加以标注和致谢的地方外，不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中明确说明并表示了谢意。

研究生签名：郭沫溪

时间：2023 年 11 月 9 日

关于论文使用授权的说明

本人完全了解中国科学技术信息研究所有关保留、使用学位论文的规定，即：中国科学技术信息研究所有权保留送交论文的打印稿和电子稿，允许论文被查阅和借阅，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。同意中国科学技术信息研究所用不同方式在不同媒体上发表、公布论文的全部或部分内容。保密的论文在解密后遵守此规定。

研究生签名：郭沫溪

时间：2023 年 11 月 9 日

导师签名：董诚

时间：2023 年 11 月 9 日

何立青

中图分类号 G350.7/TP391.2

UDC 004

学校代码 80901

密 级 公开

中国科学技术信息研究所

硕士学位论文

融合上下文信息的科技文献标题的机器翻译

Research on Machine Translation for Titles of Scientific Papers
with Contextual Information

作者姓名 郭姝澳 学 号 809012132

导师姓名 董诚 职 称 研究员

导师姓名 何彦青 职 称 研究员

学位类别 管理学 学位级别 硕士

学科专业 竞争情报 研究方向 技术竞争情报

中国科学技术信息研究所

论文提交日期（2023年10月）

致 谢

在中信所读研的两年半时光即将结束，心中感慨万千。读研路上受到太多人的关爱与照顾，提携与帮助。感激之情溢于言表，特写此铭记这些深深影响到我的人。

首先特别感谢我的两位导师，董诚老师和何彦青老师。董诚老师高屋建瓴，在我论文的主题把握和答辩表达上总能提出关键的问题和深刻的看法，令我受益匪浅，帮助我牢牢掌握论文核心，提升我的表达思维。董诚老师对事物深刻的看法和洞察力深刻影响着我，希望自己以后在科研道路上也能逐渐培养起对科研问题的洞察力和表达能力。何彦青老师是我在研究生阶段最大的幸运，她开启了我的自然语言处理研究之路，是我的学术引路人。她对待工作勤奋负责，对待科研严谨认真，指导学生尽心尽力，耐心包容。每周一次不曾间断的组会付诸着何老师指导学生付出的心血，持续性系统性的面对面学术交流使我受益良多，在学术道路上日渐进步。从毕业论文的选题、开题到中期以及最后的毕业论文收尾，每一次的定稿答辩，无论是论文的写作还是 PPT 的制作，她一路陪伴着我，耐心指导着我，以严谨的态度引领我在科研道路上精益求精。那些何老师陪我逐字逐句修改论文的时光永远难忘，至今回忆起来仍感动不已。何老师身上的优秀品质将永远影响着我，激励我在学术道路上继续前行。

感谢方法中心的刘志辉主任、王莉军主任、姜秀兰老师等其他全体老师为中心研究生们提供的优质资源和学习方面的帮助与照顾。感谢课题组的徐红姣老师、兰天老师、潘优老师、许德山老师和李颖老师在平时学习工作中给予的支持和指导。感谢刘文斌师兄、郭航程师兄、邓宁远师妹和胡卓凡师弟等的相互鼓励 and 热心帮助，让我在轻松愉悦的氛围中进行学习和研究。

感谢研究生部的张泽玉主任、李唯依老师、孙依萱老师等其他老师在研究生阶段提供的帮助与照顾。感谢学生公寓宿管阿姨和全体后勤人员提供的良好生活环境。感谢 2021 级同窗的 34 名同学，是你们温暖了我的研究生生活，给予我深刻又隽永的友谊。

感谢我的爸爸妈妈，你们在养育我这二十多年时光里对我倾注的爱和关怀，支持与陪伴是我人生最大的财富也是我乐观面向未来的最大底气，感谢你们教会我爱与被爱，让我成为一个拥有幸福能力的人。感谢我的姐姐和所有家人，在背后默默支持着我，让我可以更专注地完成学业，希望你们永远健康快乐。

感谢本文参考文献涉及的每位作者。感谢参加本论文评审和答辩的各位专家老师，你们的建议和指导是本论文得以完善的重要组成部分。

融合上下文信息的科技文献标题的机器翻译

摘 要

标题是对文献中心内容和核心观点的高度总结，通过简洁并专业的语言来表述文献主旨，帮助读者快速明确文献主题。对标题进行机器翻译，既有利于科研人员快速获取需要的跨语言文献，提升工作效率；又便于知识服务商进行跨语言知识服务，促进全球化知识共享。

本文以科技文献标题的俄汉机器翻译为研究对象。从文本特征来看，标题为含有专业术语的短文本，缺乏上下文信息导致其语义表达不够充分，已有的标题翻译研究通过构建一些外部知识或者语料库来做补充，这些外部知识的补充方式不一定适用于标题的上下文信息获取。就语种而论，俄汉平行语料规模相对较小，而俄英和英汉平行语料则更为富足，因此通常将英语作为枢轴语言来提升俄汉间的机器翻译性能，已有的枢轴迁移方法通常采用直接迁移的方式，其预训练-微调的模式存在输入输出词不匹配且无法覆盖下游标题语料的问题。

针对上述问题，本文提出融合上下文的科技文献标题俄汉机器翻译方法。本研究包括三个部分：（1）**提出了基于大语言模型的标题上下文获取方法**。科技文献摘要中蕴藏的专业词汇与标题中的术语最为相近，是对标题最专业的上下文补充信息。本文采用多策略来获取标题的摘要，在自有论文库查询机制和网络检索机制来获取该标题的真实摘要无果的前提下，实现了基于大语言模型的摘要生成模型，设计 Prompt 通过大语言模型预训练-微调机制来生成与标题相近的专业性摘要。实验显示从大语言模型获取的摘要信息与标题的真实摘要进行对比其 Rouge-1 值达到 90 分左右，基本满足了标题的专业性上下文信息补充的需求。（2）**提出了基于枢轴词嵌入生成器的俄汉神经机器翻译模型**。首先在拥有海量数据的俄英平行语料和英汉平行语料上分别预训练俄英机器翻译模型和英汉机器翻译模型，之后分别迁移俄英模型的编码器参数和英汉模型的解码器参数到基于少量的俄汉平行语料的俄汉模型上进行初始化以及微调，本文设计枢轴词嵌入生成器将其引入到这个迁移学习网络中来缓解迁移前后的词不匹配问题。经实验验证该模型 Bleu4 打分比强基线系统高 3.14 分，模型具备很好的开放性和鲁棒性，未登陆词大量减少。（3）**提出了融合上下文信息的科技文献标题的俄汉机器翻译模型**。利用上述两个方法获得标题的初始译文和上下文信息译文之后，本研究构建多编码器融合翻译模型，采用外部融合和内部融合两种策略将上下文表示融合进标题翻译模型中，从而生成更准确的标题最

终译文。经实验验证该模型的 Bleu4 打分比不融合的初始翻译模型高 1.22 分，融合翻译模型可以充分理解标题的语义信息，有效提升了标题的译文质量。

综上所述，融合上下文的科技文献标题机器翻译方法能有效对标题这样的短文本进行专业性上下文信息补充，利用英语作为枢轴语言能获取到较好的标题初始译文和上下文译文，再融合这些信息实现科技文献标题的俄汉机器翻译效果的提升。

本研究共有 23 张图和 14 张表，引用参考文献总数为 81 篇，英文参考文献为 65 篇。

关键词：低资源机器翻译；迁移学习；词嵌入生成；大语言模型；上下文融合
分类号：G350.7；TP391.2

Research on Machine Translation for Titles of Scientific Papers with Contextual Information

Abstract

A paper's title is its summary of the central content and core viewpoints with concise and professional language to express its main idea and help readers quickly clarify its topic. Machine translation of titles is not only conducive to the rapid acquisition of researchers' desired cross language literature and improvement of work efficiency, It also facilitates knowledge service providers to provide cross language knowledge services and promotes global knowledge sharing.

This paper focuses on the machine translation of scientific papers' titles from Russian to Chinese. Titles are short texts containing specialized terminology, and their semantic expression is often limited due to the lack of contextual information. Existing research on title translation has attempted to address this issue by incorporating external knowledge or corpora, but it is a challenge to ensure that the added information is relevant and specialized to the titles. Moreover, the availability of Russian-to-Chinese parallel corpora is relatively limited compared to Russian-to-English and English-to-Chinese parallel corpora. Therefore, English is commonly used as a pivot language to enhance the machine translation performance between Russian and Chinese. However, existing pivot-based transfer learning methods using direct transfer in the pretraining-finetuning mode suffer from input and output word mismatches.

To address these challenges, this paper proposes a method that integrates context into the machine translation of scientific papers' titles from Russian to Chinese. The study consists of three parts: (1) **Introducing a context acquisition method based on large language model**. Professional vocabulary hidden in scientific papers' abstracts is highly related to the terminology in titles, so Abstracts can provide the most specialized context supplement to titles. This paper employed multiple strategies to obtain abstracts. When existing paper database query mechanisms and web retrieval mechanisms fail to obtain the real abstract for the title, an abstract generation model based on large language models is implemented by using various prompts for large language model pretraining-finetuning to generate professionally similar abstracts to the title. Experimental results show that the abstract information obtained

from the large language model achieves a Rouge-1 score of approximately 90, effectively meeting the demand for professional context supplementation for titles. (2) **Proposing a Russian-to-Chinese neural machine translation model based on pivot word embeddings.** Initially, Russian-to-English and English-to-Chinese machine translation models are pretrained on massive data from Russian-English and English-Chinese parallel corpora, respectively. Then, the encoder parameters of the Russian-to-English model and the decoder parameters of the English-to-Chinese model are transferred and fine-tuned on a small-scale Russian-to-Chinese parallel corpus. To address word mismatch issues during the transfer, a pivot word embedding generator is introduced into the transfer learning network. Experimental validation shows that the model's Bleu4 score outperforms the strong baseline system by 3.14 points, displaying strong openness and robustness, with a significant reduction in out-of-vocabulary words. (3) **Constructing a Russian-to-Chinese machine translation model for scientific papers' titles that incorporates contextual information.** Utilizing the two aforementioned methods to obtain initial translations of titles and contextual information translations, this paper gave a multi-encoder integration translation model. External and internal integration strategies are adopted to integrate context representations into the title translation model, generating more accurate final translations of titles. Experimental results shows that the model's Bleu4 score outperforms the strong baseline system by 1.22 points. The combination translation model effectively comprehends the semantic information for titles, significantly enhancing the quality of title translations.

In conclusion, the combination of context into Russian-to-Chinese machine translation of scientific papers titles effectively supplements professional context information of titles. English as a pivot language enables to obtain high-quality initial translations of titles and context translations, thereby enhancing the Russian-to-Chinese machine translation of scientific papers' titles.

There are 23 pictures and 14 tables in this study, with 81 references and 65 references in English.

Keywords: Low-resource machine translation; Transfer learning; Word embedding generator; Large language model; Context integration

目 录

致 谢	I
摘 要	II
1 绪论	1
1.1 研究背景	1
1.2 研究意义	3
1.3 研究架构	3
1.4 创新之处	6
1.5 章节安排	6
2 相关研究与技术	7
2.1 短文本翻译	7
2.1.1 短文本翻译模型	7
2.1.2 短文本翻译表现	10
2.1.3 短文本翻译方法	10
2.2 基于迁移学习的低资源机器翻译	11
2.2.1 基于单侧语言的迁移学习	12
2.2.2 基于枢轴语言的迁移学习	13
2.2.3 基于多语言的迁移学习	15
2.3 标题翻译	16
2.3.1 标题人译	16
2.3.2 标题机译	17
2.4 其他相关技术	18
2.4.1 大语言模型	18
2.4.2 多编码器融合机制	19
2.4.3 词嵌入生成器	20
2.5 小结	23
3 科技文献标题上下文抽取研究	25
3.1 引言	25
3.2 抽取方法	26
3.2.1 论文库查询机制	26
3.2.2 Web 检索机制	27
3.2.3 大模型生成机制	27
3.3 实验	29
3.3.1 实验数据	29

3.3.2 实验设置	30
3.3.3 实验结果	31
3.4 小结	33
4 基于枢轴词嵌入生成器的俄汉机器翻译研究	34
4.1 引言	34
4.2 模型	35
4.2.1 跨语言预训练	35
4.2.2 枢轴-目标预训练	36
4.2.3 枢轴词嵌入生成器	36
4.3 实验	39
4.3.1 数据处理	39
4.3.2 实验设置	41
4.3.3 实验结果	41
4.4 小结	44
5 融合上下文信息的科技文献标题的机器翻译	45
5.1 引言	45
5.2 模型	45
5.2.1 上下文信息	46
5.2.2 融合模型	47
5.3 实验	49
5.3.1 实验数据	49
5.3.2 实验设置	50
5.3.3 实验结果	50
6 总结与展望	53
6.1 总结	53
6.2 展望	53
参考文献	55
作者简介	63
学位论文数据集	65

图目录

图 1.1 研究框架图	4
图 1.2 整体流程图	5
图 2.1 神经机器翻译 Transformer 模型架构图	8
图 2.2 知识图谱增强实体翻译	11
图 2.3 基于枢轴的迁移学习方法	13
图 2.4 基于分步训练的枢轴迁移学习	14
图 2.5 基于枢轴适配器的枢轴迁移学习	14
图 2.6 基于跨语言编码器的枢轴迁移学习	15
图 2.7 GPT 整体模型结构	18
图 2.8 外部融合	20
图 2.9 内部融合	20
图 3.1 科技文献标题摘要示例	25
图 3.2 标题上下文信息获取机制	26
图 3.3 基于 Web 的标题上下文检索流程	27
图 3.4 大模型直接推理提示词 (prompt) 示例	28
图 3.5 微调大语言模型方法	28
图 4.1 基于枢轴词嵌入生成器的模型架构	34
图 4.2 自编码结构	36
图 4.3 跨语言词嵌入生成器工作流程	37
图 4.4 目标词嵌入生成器工作流程	39
图 5.1 融合翻译模型构建流程	46
图 5.2 对上下文信息进行外部融合的标题翻译模型	48
图 5.3 对上下文信息进行内部融合的标题翻译模型	49

表目录

表 3.1 预处理后数据规模	30
表 3.2 大模型直接推理的实验设置	31
表 3.3 大模型微调参数设置	31
表 3.4 web 检索机制的检索率	31
表 3.5 web 检索机制质量评估	32
表 3.6 大模型生成机制质量评估	32
表 4.1 预处理后语料规模	40
表 4.2 基于枢轴词嵌入生成器的机器翻译模型实验设置	41
表 5.1 摘要内容作为上下文	46
表 5.2 标题作为上下文	47
表 5.3 实验设置	50
表 5.4 融合上下文信息的标题翻译结果	50
表 5.5 融合标题类上下文信息的标题翻译结果	51
表 5.6 融合摘要类上下文信息的标题翻译结果	51

缩写清单

ST	短文本 (Short Texts)
MT	机器翻译 (Machine Translation)
PBSMT	基于短语的统计机器翻译 (Phrase-based Statistical Machine Translation)
NMT	神经机器翻译 (Neural Machine Translation)
LLM	大语言模型 (Large Language Model)
GPT	生成式预训练模型 (Generative Pre-trained Transformer)
Bi-LSTM	双向长短期记忆网络 (Bi-directional Long Short-Term Memory)
CNN	卷积神经网络 (Convolutional Neural Networks)
RNN	循环神经网络 (Recurrent Neural Networks)
BLEU	双语替补评估 (Bilingual Evaluation Understudy)
ROUGE	基于召回的摘要替补评估 (Recall-Oriented Understudy for Gisting Evaluation)
BPE	字节对编码 (Byte Pair Encoding)
OOV	未登录词 (Out Of Vocabulary)
PEG	枢轴词嵌入生成器 (Pivot Embedding Generator)

1 绪论

1.1 研究背景

如何快速识别并挖掘出目标技术主题文献是技术竞争情报工作中一直备受关注的问题。标题作为标明文章和作品内容的词组、短语或短句^[1],它以简洁的文字展现论文的中心内容和重要论点,使读者能从中了解到该文所要研究的核心内容和主要观点;同时可提供给二次文献机构的数据库系统进行检索和收录,供标引者选用和读者检索^[2]。在这个知识爆炸与万物互联时代,科技文献的语种多样化和海量规模势必带来文献标题的复杂呈现,为科技情报人员的研究工作带来一定阻碍。对于需要经常阅读科技文献标题的科研人员来说,高质量的标题翻译可以帮助读者快速获取所关注技术主题的跨语言文献,提升工作效率。人工翻译海量文献的标题费时费力,因此提升科技文献标题的机器翻译效果是提高科技情报人员工作效率的必需,也是促进跨语言知识关联与发现,完备跨语言知识服务的必要选择。

文献标题的翻译涉及到机器翻译(Machine Translation, MT)领域中的短文本翻译技术。短文本(Short Texts, ST)是指含有较少字符的文本。当下对科技文献的机器翻译研究多集中于摘要、正文等长文本,针对标题这样的短文本的机器翻译研究较少。短文本包含词汇元素少,从句法结构上其翻译难度要远远小于长文本。但在实际应用中由于短文本缺少上下文信息导致自身语义表征不足从而机器翻译效果并不理想。如何提升短文本的翻译效果是机器翻译领域的一大难题。目前效果最好的短文本翻译技术主要有基于短语的统计机器翻译(Phrase-based Statistical Machine Translation, PBSMT)^[3]和神经机器翻译(Neural Machine Translation, NMT)^[4]。基于短语的统计机器翻译将源语言句子切分为短语¹的组合,根据从双语语料库中获取到的短语翻译知识把每一个源语言短语翻译成目标语言短语的可能性用概率表示,利用这些短语的译文组合成待翻译句子的候选译文并经由统计模型生成最佳译文^[5]。神经机器翻译系统通过神经网络直接实现自然语言之间的自动翻译^[6]。目前基于 Transformer 构架的神经机器翻译模型已成为机器翻译的主流模型,其强大的注意力机制使得模型的上下文建模能力增强,机器翻译效果提升明显。无论是基于短语的统计机器翻译还是神经机器翻译都属于数据驱动型的机器翻译技术,其性能主要依赖于双语语料的规模,质量和领域覆盖面。

利用上述翻译模型进行短文本翻译时研究者经常会采用平衡训练集长度分

¹ 非句法意义上的短语,词串、单词也属于短语。

布和融入外部知识的方法增加短文本翻译效果^[7]。本文的研究对象是俄语科技文献的标题汉译，上述机器翻译方法针对该问题存在如下难点。其一，不同语种的标题会有不同的语用特征和表达范式，例如英语中介词短语结构的标题“On the Units of the Equilibrium Constant”会被翻译成动宾结构的中文标题“试论平衡常数的单位”，这里的“on”会被翻译成“试谈”或者“试论”，而在一些其他结构的标题中“on”被翻成“面向”或者“基于”更加准确，不同结构的标题中介词的翻译会有所不同^[8]。如何通过不同语种间语用特征和表达范式的转换提升翻译质量是俄汉标题机器翻译的一项挑战。其二，科技论文的标题翻译是一项极具专业性工作，与通用领域不同的是标题中含有极具领域性的专业术语，标题自身没有足够的上下文来对其蕴含的隐藏信息进行补充，因此如何挖掘标题的专业性上下文来辅助翻译术语也是标题机器翻译面临的一项挑战。其三是将俄语的科技文献标题翻译成汉语属于低资源语言的机器翻译问题。低资源语言（Low-resource Language）是相较于英汉这种使用广泛、拥有大量平行语句的富资源语言（High-resource Language）而言的，它使用范围相对较小，相关数据稀少，平行句对资源缺乏甚至会有“零资源”情况存在。因此低资源语言机器翻译无论使用基于短语的统计机器翻译方法还是神经机器翻译方法都不能达到令人满意的效果。目前低资源语言机器翻译常用的方法有数据增强方法、级联翻译方法、迁移学习方法、知识蒸馏方法和无监督翻译方法等^[9]。从已有研究涉及的数据领域来看，当下的低资源语言机器翻译研究更多涉及新闻演讲等通用领域，鲜少像科技论文标题这样专业领域的研究。从语种的范畴来看，当下的低资源语言机器翻译研究多集中于欧洲语言场景，汉语与其他低资源语言间的机器翻译研究相对较少。就俄汉翻译而言，俄英数据和英汉数据相对而言较为丰富，属于富资源语言，因此从模型构建角度采用迁移学习方法将富资源语言知识迁移到低资源语言任务上更为合适。从语言学分析来看，当下的低资源语言机器翻译研究多以改进算法模型提高翻译质量为主，缺乏必要的语言学知识，因此向模型补充必要的语言学知识是提升标题机器翻译质量的一个重要途径。生成式预训练模型（Generative Pre-trained Transformer, GPT）是大语言模型（Large Language Model, LLM）的一种，其通过在海量数据上进行训练从而获得执行自然语言处理任务的通用能力^[10]。如何借助大语言模型广泛的知识来辅助标题机器翻译也是本文研究的重点。

综上所述，本研究拟开展针对科技文献标题的俄汉机器翻译研究，从语言学角度借助大语言模型构建标题外部上下文知识的获取途径，将其以有效的策略融入到基于迁移学习的俄汉低资源机器翻译神经网络中，实现大模型技术、短文本翻译技术与基于迁移学习的低资源机器翻译技术的结合，提升科技文献标题的翻译效果。

1.2 研究意义

本文的研究目的是利用多策略构建标题上下文信息的获取途径，借助枢轴语言英语设计俄汉机器翻译模型，进而实现该翻译模型与外部上下文知识的融合最终提升科技文献标题的俄汉机器翻译效果。

在理论意义上，首先本文深入分析了科技文献标题所需的上下文信息的获取渠道，以其对应的摘要信息作为最合适的上下文，借助目前最为流行的大语模型高效微调技术微调一个摘要生成模型，通过它来自动获取标题上下文，为大模型辅助机器翻译研究提供了一种借鉴。其次本文从低资源语言的迁移学习方法中预训练-微调模式存在的输入和输出词不匹配问题出发，通过构建枢轴词嵌入生成器来弥合迁移前后存在的子词差异问题提升低资源机器翻译质量。此研究在子词粒度上缓解了迁移前后词不匹配问题，为低资源机器翻译研究提供了一种方法参考。

在应用价值上，对学术交流而言，对文献标题进行机器翻译可以打破语言障碍，帮助科研人员快速检索到所需的目标技术主题的跨语言文献，提升其工作效率和学习效率，扩展论文辐射范围，提升其二次引用率，促进国际间的学术交流与合作。就知识服务而论，良好的科技文献标题机器翻译效果可以促进跨语言知识关联与发现，赋能跨语言知识协作，增进公众的跨语言知识理解，能有效提升知识服务商的跨语言知识服务水平和市场竞争力。

1.3 研究架构

本研究旨在基于上下文信息进行科技文献标题的俄汉机器翻译，从上下文信息获取、俄汉翻译和标题翻译三个方面出发提出了三个问题，分别是：如何获取精准可利用的标题上下文？如何优化枢轴翻译提升俄汉机器翻译？如何融合上下文提升俄汉标题机器翻译？




图 1.1 研究框架图

针对以上三个问题，本文的研究架构如图 1.1 所示，主要包括文献调研、研究思路、实证分析、结果评估与总结四个阶段，具体而言：

（1）文献调研。

对本研究涉及到的短文本机器翻译、基于迁移学习的低资源机器翻译、标题翻译、大语言模型，词嵌入生成器和融合翻译等的相关研究分别进行文献调查和综述，了解其背后机理和相关工作进展。

（2）研究思路。

针对三个问题，进行文献调研后，得出本文的研究思路。针对标题上下文信息获取的问题，本文将摘要作为精准可利用的标题上下文信息；针对枢轴翻译存在的问题，本文引入词嵌入生成器来优化枢轴翻译提升俄汉机器翻译效果；针对融合上下文信息提升标题翻译的问题，本文提出融合标题上下文信息的方法。

（3）实证分析。

针对三个问题提出各自对应的研究思路后，分别设计标题上下文获取模型、基于迁移学习的俄汉低资源机器翻译模型、融合上下文信息的科技文献标题机器翻译模型，并对以上三个模型分别进行实验验证。

（4）结果评估与总结阶段。

ROUGE（Recall-Oriented Understudy for Gisting Evaluation）是南加州大学

在 2004 年提出的一种基于召回率的摘要替补评估方法^[11]，广泛应用于摘要的自动评价。本文利用 BLEU 和 ROUGE 两个指标对标题上下文获取效果进行评估。BLEU (Bilingual Evaluation Understudy) 是一种用来评估机器翻译质量的双语替补评估方法，由 2002 年 IBM 公司提出^[12]。因其自动高效可靠性强的评估特点它目前已广泛应用于机器翻译领域的评估任务，本文采用 BLEU 对基于迁移学习的俄汉低资源机器翻译模型和融合上下文信息的科技文献标题机器翻译模型进行翻译效果评价。最后分析实验结果数据，总结现有工作进行未来展望。




图 1.2 整体流程图

基于上下文信息进行科技文献标题机器翻译的整体流程图如图 1.2 所示，可以分成上下文信息抽取、标题及上下文翻译、融合翻译三个部分，分别对应本文研究的三部分内容：

(1) 标题上下文信息获取模型。

科技文献标题经预处理后输入标题上下文获取模型，获取标题的上下文信息。获取到的上下文信息可以对标题的含义做一个专业的补充和解释，方便机器翻译模型更好地理解标题的语义信息从而获取较好的标题译文。本文构建三种标题上下文信息的获取机制，分别是已有论文库查询机制、web 检索机制和大模型生成机制。本文首先在自有论文库查询，如果查询不到就通过在 Bing API 平台的一系列检索规则来进行 web 上下文抽取，再获取不到则通过大语言模型的提示词设计和微调方式来获取一个能根据标题生成上下文的模型。三种上下

文信息获取机制的构建可以帮助标题有效快速地获取专业性上下文信息，为之后的融合翻译做好准备。

(2) 基于枢轴词嵌入生成器的机器翻译模型。

在构建俄汉机器翻译模型的过程中，首先在拥有海量数据的俄英平行语料和英汉平行语料上分别预训练俄英机器翻译模型和英汉机器翻译模型。之后分别迁移俄英模型的编码器参数和英汉模型的解码器参数到基于少量俄汉平行语料的俄汉模型上进行初始化然后微调。本文构建了枢轴词嵌入生成器将其引入整个迁移学习网络中来缓解迁移前后的词不匹配问题，有效提升俄汉低资源机器翻译的翻译质量，力求获得良好的标题初始译文和上下文信息译文，为之后的融合翻译奠定基础。

(3) 融合上下文信息的标题机器翻译模型。

获取标题的上下文信息后，将标题和上下文信息分别输入基于枢轴词嵌入生成器的俄汉低资源机器翻译模型，获得标题译文和上下文信息的译文。之后采用多编码器对标题和上下文信息的源语言句子和译文句子进行编码，通过外部融合和内部融合策略最终获取满意的科技文献标题的译文。

1.4 创新之处

本文具有如下创新点：

(1) 设计从大语言模型获取标题的专业性上下文的策略。

大语言模型具有广泛的知识强大的自然语言处理能力，本文尝试从大语言模型获取标题的上下文信息，通过提示词（Prompt）^[13]和下游微调等方法获取与标题相关性很强的类似摘要的上下文信息，有利于提升标题翻译效果。

(2) 构建基于枢轴词嵌入生成器的低资源翻译模型。

本研究将词嵌入生成器引入基于迁移学习的低资源机器翻译中，构建基于枢轴词嵌入生成器的机器翻译模型。这种方法可以有效提升模型鲁棒性和词表开放性，在低资源机器翻译领域有广泛的适用性。

(3) 构建融合摘要作为上下文信息的科技文献标题机器翻译模型。

科技文献标题由于其文本较短语义不足且多含有专业词汇，对其机器翻译效果并不理想。本文通过多编码器策略来融合标题上下文信息，可帮助机器翻译系统充分理解标题含义，进而提升科技文献标题的机器翻译质量。

1.5 章节安排

本论文共分为六个章节，具体安排如下：

第一章为绪论。本章介绍研究背景、研究意义、研究架构、创新之处和章节安排。

第二章为相关研究与技术。本章从短文本机器翻译、基于迁移学习的低资源机器翻译、标题翻译、大语言模型、词嵌入生成器和融合翻译技术等内容上对国内外相关研究进展进行介绍。

第三章为科技文献标题上下文抽取研究。本章首先确认摘要是否是标题最好的上下文信息，之后构建了三种获取标题上下文信息的机制，分别是已有论文库查询，web 上下文检索和基于大模型的生成。通过在自有论文库中进行 SQL 语句查询获取标题对应的真实摘要；通过在 Bing API 平台设计一系列检索规则来进行 web 上下文的检索；通过基于大模型提示词设计和下游任务微调方式来获取一个能根据标题生成上下文的模型。实验中对 web 上下文检索机制的检索效率和获取的摘要质量进行了评价，对不同提示词下的大语言模型表现和微调后的语言模型表现进行了比较。

第四章为基于枢轴词嵌入生成器的俄汉机器翻译研究。本章首先探讨了基于迁移学习的低资源机器翻译方法目前存在问题和不足，然后提出了将枢轴词嵌入生成器引入迁移学习网络的方法来弥合迁移前后的子词差异问题进而提升整个低资源机器翻译质量。之后介绍了词嵌入生成器的构建原理和整个迁移学习模型的训练步骤。最后在俄英、英汉、俄汉通用数据和标题数据上进行多个基于迁移学习的俄汉翻译实验，并给出了数据来源和处理过程、实验设置和结果分析。

第五章为融合上下文信息的科技文献标题的机器翻译。为了提高科技文献标题译文的准确性，本文对其进行融入上下文信息的标题机器翻译研究。本章介绍了将上下文信息融合到标题翻译系统的方法，并对融合什么样的上下文信息更有益于标题翻译这个问题进行研究，在两种融合翻译策略上使用不同的上下文信息进行实验验证，并进行结果分析。

第六章为总结与展望。本章首先对融合上下文信息的科技文献标题的机器翻译方法进行总结分析，然后就本文工作需要改进的地方和未来的研究方向进行了展望。

2 相关研究与技术

本章围绕短文本机器翻译、基于迁移学习的低资源机器翻译、标题翻译、大模型技术和词嵌入生成器等内容分别对国内外相关研究进行梳理和总结，归纳出每类内容的技术重点和研究偏重，从中捕获出本文可行的研究方向和思路。

2.1 短文本翻译

2.1.1 短文本翻译模型

短文本翻译经常使用的翻译模型有基于短语的统计机器翻译模型和神经机器翻译模型。

(1) 基于短语的统计机器翻译。

1993 年，IBM 的 Brown 和 Pietra 等人^[14]提出统计机器翻译的数学模型，即噪声信道模型，它将统计机器翻译过程视为信息传输过程，即源语经噪声信道发生扭曲变化后产生译语。统计机器翻译的任务在于将观察到的源语恢复为最有可能的译语，即同一源语句段可能对应多个候选译语句段，出现概率最大的便是译文。

最初的统计机器翻译是基于词的统计机器翻译，可以处理单词对目标语言单词的“一对多”情况，对单词和目标语言单词的“多对一”情况则无法处理。另外由单词组成的短语的含义常常会与每个单词含义组合后的语义相差很远，例如短语“after all”中文含义为“毕竟”，但两个单词分开翻译则成“之后所有”，基于词的统计机器翻译同样不能处理这种情况。所以 2004 年爱丁堡大学的 Koehn 提出基于短语的统计机器翻译方法^[3]。它的建模思想是：将源语言句子划分为由 n 个短语（一个连续的词串，并不指句法意义上的短语）的序列，然后将每个短语翻译为目标语言短语，从而生成目标语言句子，在所有目标语言句子中选一个概率最高的句子，式 2.1 为其数学模型。

$$\hat{e}_1^j = \operatorname{argmax}\{Pr(e_1^j|f_1^j)\} \quad (\text{公式 2.1})$$

式中， $f_1^j = f_1, \dots, f_j, \dots, f_J$ 表示将源语言句子 f_1^j 连续切分成 J 个短语的单词序列。

$e_1^j = e_1, \dots, e_j, \dots, e_J$ 表示将之前由 J 个短语组成的源语言句子序列中每个短语翻译成目标短语生成的目标语言句子。 argmax 表示从目标语言中生成输出句子的搜索问题。

在基于短语的统计机器翻译方法被提出后又有基于句法的统计机器翻译被大量研究用来改善基于短语方法中存在的不足^[15]，例如短语与短语之间的关系

未被很好地考虑到，短语之间的长距离依存关系难以处理且泛化能力差等。但总的来说，基于短语的统计机器翻译模型在翻译质量上优于基于词的翻译模型，同时又比基于句法的翻译模型训练速度快、解码效率高，故其在统计翻译时代成为了主流。尤其它以短语为单位进行建模解码的方式，在标题类短文本机器翻译任务上适用性更强，拥有更为优越的翻译性能。

(2) 神经机器翻译。

神经机器翻译是指通过神经网络实现源语言到目标语言翻译的方法。不同于统计机器翻译的离散表示方法，它采用连续空间表示方法对词、短语、句子进行表示^[6]。2013 年 Kalchbrenner 和 Blunsom 将神经网络应用于机器翻译，提出了一种端到端的“编码器-解码器”框架，编码器采用卷积神经网络结构，将源语言句子转化为一个连续向量，通过递归神经网络的解码器将其转化为目标语言句子^[16]。2014 年 Sutskever 等人将长短记忆网络引入端到端神经机器翻译，编码器和解码器都采用递归神经网络结构^[17]。之后又有研究采用编码器和解码器都为循环神经网络结构的方法将编码器和解码器进行联合训练，结果证明这种方法的翻译性能提升很大^[18]。2015 年，Bengio 首次将注意力机制引入神经机器翻译模型，考虑到解码器生成源语言句子对应的目标词时该目标词的选择仅与其对应的源语言词语相邻的几个词有关，与其他源语言词语没有关系，因此为每个目标词动态生成源语言的上下文向量^[19]。之后注意力机制在机器翻译中的应用扩散为全局注意力机制和局部注意力机制^[20]。




图 2.1 神经机器翻译 Transformer 模型架构图

2017 年, Vaswani 等人提出了基于完全注意力机制的 Transformer 模型^[4], 这个模型实现了训练数据的并行计算, 在对长文本进行预测时可以捕捉较长的语义关联。此模型的翻译质量和训练效率上相对统计机器翻译都有很大的提升, 目前已成为神经机器翻译领域的主流模型。模型工作机理介绍如下:

如图 2.1 所示, Transformer 的结构是一个标准的“编码器-解码器”结构。依据功能不同模型整体分为四部分, 分别是输入模块、编码模块、解码模块和输出模块。首先输入模块负责机器翻译训练数据中源语言和目标语言文本的嵌入和位置编码, 文本嵌入指将文本数据转化为空间向量来表示其语义信息, 位置编码指在文本嵌入的基础上补充文本中词汇的位置信息, 结合两种信息内容的空间向量便于在训练中捕捉高维空间向量词汇间的关系, 深度理解文本的语义内容。第二部分的编码模块用来对输入的源语言文本信息进行特征提取, 主要依赖编码器结构。一个编码模块可以由多个编码器堆叠进行连续编码。如图 2.1 左侧部分所示, 每个编码器由 2 个子层连接结构组成, 第一个子层连接结构包括一个多头自注意力子层、规范化层和一个残差连接。第二个子层连接结构包括一个前馈全连接子层、规范化层和一个残差连接。其中, 多头自注意力子层是对自注意力机制的一个扩展和完善。编码器中的自注意力机制是指在对某个词语进行编码表示时, 神经网络只会关注它相邻区域的词语的信息, 不再关注与其相距较远的无关的词语信息。自注意力机制可以提升编码效率和聚焦当前词语的关键信息, 但在编码过程中自注意力机制的应用会过度的将注意力集中于自身位置的问题导致句子的局部信息被忽略。因此多头自注意力机制通过进行多组的自注意力处理过程在来优化每个词汇的不同特征部分, 均衡同一种注意力机制可能产生的偏差, 让词义拥有来自更多元的表达。前馈全连接子层用来增强多头注意力机制中对源语言信息的拟合能力。规范层 (Layer Normalization, NL)^[21]用来对神经网络模型进行标准化处理, 避免经过多层计算后参数出现过大或过小情况影响模型收敛速度。残差连接 (Resnet)^[22]用来解决深度学习网络中的梯度消失问题。第三部分解码模块负责根据编码器输出的信息进行目标语言的特征提取, 即对编码器信息对应的源语言句子计算出目标语言的翻译过程。一个解码模块可以由多个解码器堆叠进行连续解码。每个解码器由三个子层连接结构组成, 第一个子层和第二个子层连接结构相同, 它们都包括一个多头自注意力子层、规范化层和一个残差连接。第三个子层连接结构包括一个前馈全连接子层、规范化层和一个残差连接。其中, 第一个子层中的多头注意力层对输入的目标语言信息采取掩码 (Masked) 操作, 因为解码器对源句子进行解码是顺序解码, 整个过程需要掩饰掉当前翻译过程之后的词语。第二个子层中的多头注意力机制用来对编码器的输出信息进行解码操作。规范化层和残差连接的作用与编码模块中的一致。最后输出模块由线性层和 softmax 层组成, 线性层用来对解码器的结果做线性变化得到指定维度的输出, softmax 层用来使最后一维的向量中的数字缩放到 0-1 的概率值域内, 并满足它

们的和为 1。最终根据概率给出目标词语的预测结果。

近些年,从循环神经网络方法、卷积神经网络方法到注意力方法,从有监督训练方法到无监督训练方法,从共享参数训练到独立参数训练等,神经机器翻译取得重要进展^[23]。与统计机器翻译相比,神经机器翻译的优势体现在其简单的模型架构,强大的翻译质量和训练效率。神经机器翻译的不足是目前没有坚固的理论对其背后作用机理进行解释,其过程和人的认知差异很大,通过人的先验知识干预结果的程度差,神经机器翻译对数据的依赖很大,双语数据的规模和质量对翻译性能都很大的影响。

2.1.2 短文本翻译表现

关于短文本在不同翻译系统上的性能表现已有很多科学家做了研究。2014 年 Cho 等人^[24]发现在循环神经网络模型上短文本和较长文本的翻译性能不佳,与此同时这些文本在基于短语的统计机器翻译模型上的翻译表现更加平稳。2015 年 Bahdanau 等人^[19]研究发现引入注意力机制的循环神经网络模型很好地改善了较长文本的翻译性能,但短文本的翻译性能和没有引入注意力机制的循环神经网络模型上的表现相比并没有多大差别。2017 年 Toral 等人^[25]从字符级别对不同长度上的基于短语的统计机器翻译和神经机器翻译性能进行对比,发现神经机器翻译在较长文本上翻译性能不如基于短语的统计机器翻译,并且在两个模型上短文本的翻译效果都远不如长文本。进入神经机器翻译时代,为了提高较长文本在神经机器翻译模型上的翻译性能,2019 年 Neishi 和 Yoshinaga^[26]研究 Transformer 模型对不同长度文本翻译性能的鲁棒性,在基于循环神经网络模型和其他三个 Transformer 的变种模型上以绝对位置和相对位置信息做变量比较位置信息与输入文本长度的关系,实验表明 Transformer 的绝对位置信息会导致输入句子长度的过拟合情况,使用相对位置信息会减少对所有长度文本数据的过拟合,对于短文本来说改成相对位置信息并没有对其翻译性能提高多少。2022 年澳门大学 Yu 等人对不同长度文本在基于统计机器翻译和神经机器翻译上的表现进行测试^[7],结果表明基于短语的统计机器翻译与神经机器翻译在短文本上的表现都不尽如人意。

根据以上研究可知短文本在神经机器翻译上的性能总体和基于短语的统计机器翻译并没有多大差别,只是略胜一筹,短文本在实际应用中目前的性能表现还远远不足。

2.1.3 短文本翻译方法

针对短文本机器翻译并不令人满意的性能表现,2021 年澳门大学 Yu 等人^[7]调研了神经机器翻译中短文本翻译面临的挑战,将短文本的翻译错误分为多翻、少翻、误翻和错序四类,并用这四个指标进行短文本翻译效果的评估。他们使用新闻领域的短文本进行实验,这些短文本主要由标题和实体组成。实验发现训练集上不平衡的数据分布会造成较高的校准误差,导致较多的“多翻”

错误；也验证了缺乏上下文信息会造成模型更高的不确定性，导致“误翻”现象增多。面对短文本翻译存在的数据分布不均衡问题，他们采用平衡训练数据长度分布的方式，对训练集中长度分布比较少少的部分进行上采样，使得每一轮训练中被训练的数据在各个长度区间内数量分布比较平均，这个方法可以极大地减少“多翻”现象。对于缺乏上下文信息的问题，他们将翻译记忆库融入进神经机器翻译模型，在翻译过程中系统会自动在翻译记忆库中搜索与原文相同或相似的翻译资源，如果有则直接给出译文。实验证明将其引入神经机器翻译系统也可以极大地改善“误翻”和“少翻”现象。对于短文本中命名实体的机器翻译，2020 年 Zhao 等人^[27]利用知识图谱的推理能力来提升神经翻译系统中实体的翻译质量。如图 2.2 所示，由双语句对中的“药品”到“drug”和“阿司匹林”到“aspirin”，可从知识图谱中找出隐藏的与“药品”和“阿司匹林”相关的“乙酰水杨酸”，而“乙酰水杨酸”与“阿司匹林”又是近义词关系，可以推导出“乙酰水杨酸”和“aspirin”的伪平行语句。之后将推理到的伪双语数据和原始双语数据一起联合训练，实验结果证明确实比原来的 BLEU 得分有提升。




图 2.2 知识图谱增强实体翻译

由上述短文本类的相关研究可以得知，目前针对短文本机器翻译模型多为神经机器翻译模型，对短文本机器翻译的改进策略多为外部知识的补充，但外部知识的选择因研究对象而异。对于本文研究对象科技文献标题来讲，如何为标题选取最相近且专业的上下文信息是非常关键的研究点。

2.2 基于迁移学习的低资源机器翻译

NMT 的成功源于数据资源和算法的成功，双语训练数据越多，神经机器翻译模型的翻译性能越好。但目前的大规模的平行语料数据都仅限于英语和其他语言，非英语场景的语言对的双语数据规模相对不足。在机器翻译研究中将这些具有较小规模平行语料的语言称为稀缺资源语言，也被称为低资源语言^[9]。

在数据因素的制约下, NMT 在低资源语言中的翻译效果并不理想。低资源语言机器翻译具有很多实际需求和应用场景, 因此引起了国内外学术界和业界的广泛关注, 已经成为当前机器翻译领域的重要研究热点之一, 也出现了很多值得关注的研究成果。

迁移学习是一种机器学习的方法, 指的是将一个预训练模型作为另一个任务训练的起点, 使其蕴含的学习经验或者知识结构迁移到目标领域或者任务, 从而改善目标领域或任务的方法。在低资源语言翻译中, 迁移学习将富资源语言对的模型参数迁移到低资源语言对上, 使低资源语言对获取到富资源语言对的翻译知识。对于本文的俄汉低资源机器翻译研究来说, 由于俄英和英汉这样富资源语言对的存在, 因此选择迁移学习方法来研究俄汉机器翻译问题最为合适。以下对基于迁移学习的低资源机器翻译研究进展进行介绍。

2.2.1 基于单侧语言的迁移学习

在迁移学习应用于低资源机器翻译最初阶段, 研究人员侧重于对低资源语言对中的一侧语言进行迁移学习。基于单侧语言的迁移学习分为源端迁移和目标端迁移。源端迁移指富资源语言对和低资源语言对共享同一个目标语言。2016 年 Zoph^[29]首次将迁移学习方法引入低资源机器翻译中。他在循环神经网络上进行基于源端的迁移学习, 首先使用富资源语言对训练了一个父模型 (Parent model), 之后将此模型的参数迁移到低资源语言对的子模型 (Child model) 上进行参数初始化。父模型和子模型中的目标语言相同, 在子模型的微调阶段目标端词嵌入继承自父模型且参数冻结不变, 源端词嵌入随机初始化, 其他参数继续训练。他的迁移学习尝试使得低资源语言的机器翻译效果取得了很大的提升, 也开拓了迁移学习在低资源机器翻译研究的广阔前景。2017 年 Nguyen 等人^[29]在 Zoph 工作的基础上进行了扩展, 探索了父模型也是低资源语言对的场景, 与 Zoph 工作不同的是微调阶段源端的词嵌入由父模型源端的词嵌入进行随机分配, 在 Transformer 神经网络架构的实验结果证明了当父模型也是低资源场景的时候迁移学习依然能够提升低资源机器翻译效果。有时候父模型参数并不是最适合于子模型的初始化参数, 2018 年 Gu 等人^[30]将元学习算法引入低资源机器翻译, 通过子模型少样的数据就可促使父模型学会对子模型最适配的参数初始化, 这种方法比之前简单微调的方法效果要好。目标端迁移指富资源对和低资源语言对共享同一个源语言。目标语言需要语言特定的表示, 但迁移学习更倾向于语言间共性的学习, 因此对目标端语言的迁移需要达到共性与特性的平衡才能提升翻译质量。相关研究通过联合训练和多阶段微调的方法对其进行实验, 但并没有特别有效的方法能提升其翻译质量^[31]。

基于单侧语言的迁移学习通过学习单侧语言与富资源语言 (通常是英语) 相关的知识, 能有效提升低资源机器翻译质量, 但如果低资源语言对中两侧语言都具有富资源语言相关的知识可供迁移, 那么整个机器翻译模型仍然具有开

发的空间。

2.2.2 基于枢轴语言的迁移学习

在低资源机器翻译中存在这样一种情况，即低资源语言对的双方都和一个共同的第三方语言存在大量平行语料，这个第三方语言被叫做枢轴语言。使用枢轴语言也是低资源机翻译中的常用方法，其常被用来做间接翻译和伪造平行语料。2019 年 Kim 将枢轴思想与迁移学习相结合提出基于枢轴的迁移学习方法并应用于低资源机器翻译^[32]。采用此方法构建的机器翻译模型如图 2.3 所示，首先在富资源的源语言-枢轴语言（简称源-枢轴）和枢轴语言-目标语言（简称枢轴-目标）平行语料上分别训练一个源-枢轴的预训练机器翻译模型和枢轴-目标的预训练机器翻译模型，之后分别迁移两个预训练模型中的源语言编码器参数和目标语言解码器参数到源语言-目标语言（简称源-目标）的下游模型进行参数初始化之后进行微调。实验结果证明微调后的迁移学习模型可以获得比之前更好的翻译效果。




图 2.3 基于枢轴的迁移学习方法

Kim 的研究中在基于枢轴的迁移学习方法上做了三种改进策略。三种策略介绍如下：

(1) 分步训练。

如图 2.4 所示，整个训练方法采用分布训练。第一步获取源-枢轴的预训练模型，第二步使用枢轴-目标的平行语料在第一步模型参数上继续训练，整个训练过程冻结编码器参数，第三步使用源-目标平行语料在第二步模型参数上进行微调。第一步训练中构建一个源语言和枢轴语言的联合词表可以使编码器更加有效的标记两种语言，也便于第二步训练过程中更好地解码枢轴语言。




图 2.4 基于分步训练的枢轴迁移学习

（2）枢轴适配器。

如图 2.5 所示，在两个预训练模型基础上直接训练一个由源-枢轴预训练模型的编码器到枢轴-目标预训练模型编码器的适配器^[33]，可以学习到两个编码器在相同含义的不同语言句子空间表示上的映射，在之后的源-目标模型的训练阶段直接使用此适配器连接进行微调，可以使编码器解码器联结的更加紧密。




图 2.5 基于枢轴适配器的枢轴迁移学习

（3）跨语言编码器。

如图 2.6 所示，在源-枢轴的预训练模型的训练阶段引入一个从枢轴语言到枢轴语言的自编码过程^[34]，编码器端由源语言句子和枢轴语言句子共同输入进行编码，两种语言由一个共享的解码器进行解码只输出目标语言句子，训练前对源-目标数据集进行联合 BPE 编码^[35]，训练时采用联合词表。




图 2.6 基于跨语言编码器的枢轴迁移学习

基于枢轴的迁移学习模型充分利用了低资源语言对与枢轴语言之间丰富的双语数据知识，促使微调后的模型对源语言的编码能力和目标语言的解码能力都大幅度提升，效果要好于基于单侧语言的迁移学习。之后又有研究^[36]将低资源语言对和枢轴语言的单语数据引入基于枢轴的迁移学习中，通过不同的冻结策略和参数共享实现了机器翻译效果的提升。虽然基于枢轴的迁移学习方法能有效提升低资源机器翻译效果，但针对迁移前后编码器解码器信息传递的误差问题仍存在着许多改进策略。由于基于枢轴的迁移学习方法得到的源-目标的机器翻译模型中其初始化参数分别来自两个预训练模型，其中源语言编码器的参数是在源语言-枢轴语言预训练中与枢轴语言的解码器一起训练而成，而非目标语言解码器；目标语言解码器的参数是在枢轴语言-目标语言预训练中与枢轴语言的编码器一起训练而成，而非源语言编码器。因此源语言编码器与目标语言解码器进行组合时，会出现参数不匹配问题，导致输入输出中词不匹配的问题。

2.2.3 基于多语言的迁移学习

多语言机器翻译模型是具有多个语言方向翻译能力的模型，其通过共享编码器解码器的方式实现对不同语言在同一空间的表示，极大提升了数据资源的利用效率^[37]。多语言机器翻译本身就是一种迁移学习，通过多个语言方向上的训练，使得模型在训练某一个语言方向的翻译能力时，会自动对其他相关语言的知识进行迁移学习。因此多语言机器翻译中涉及的语言方向越多，可供迁移学习的知识越多，对其中的低资源语言对的机器翻译效果提升越明显^[38]。对于零样本机器翻译，虽然没有直接的训练数据，但多语言翻译模型经过与其相关语言知识的迁移学习，可以具有一定的零样本翻译能力^[39]，这是它的一个极大优势。多语言模型的特点是所有语言都在同一空间表示，但不同语言本身在词汇和语法上存在差别，会导致不同语言的学习过程以及学习到的特征发生冲突，影响最后的翻译效果。因此一些研究通过为每种语言引入额外的向量层保持每种语言的特征^[40]或者采用相似语言训练的方法^[41]等来缓解特征冲突。

虽然多语言机器翻译能有效提升低资源机器翻译效果，但对于某一个低资源机器翻译任务来说，采用多语言的迁移学习需要大量不同语言方向的训练数

据, 整个训练成本会大大提高。

综上所述, 对基于迁移学习的低资源翻译来说, 基于单侧语言迁移方法多用于早期的研究中, 基于枢轴语言的迁移学习方法适用于具有枢轴语言的低资源语言对中, 基于多语言的迁移学习方法迁移效果好但训练成本高。对于本文的俄汉机器翻译来说, 基于枢轴语言的迁移学习方法最为合适, 但其仍存在着改进空间来缩小迁移前后中信息误差传递。科技标题中存在着众多领域词汇, 微调阶段势必存在着大量未登陆词。如何缓解信息传递误差和未登陆词问题是我们研究的重点。

2.3 标题翻译

由于标题在整篇科技文献文本中的特殊性, 其翻译方法是外国语翻译工作中一个非常重要的内容, 在翻译研究中有许多针对于标题翻译的理论和方法总结。用机器对标题进行翻译更是一件具有难度的事情, 对标题进行机器翻译必须要参考现有的标题翻译理论知识, 才能获得更好的翻译效果。以下是针对标题翻译的人译研究和机器翻译研究。

2.3.1 标题人译

标题的翻译是件极具专业性和复杂性的工作, 其中的专业术语翻译是最具有难度的一部分。在对科技文献进行标题翻译的工作中, 一线的翻译人员总结了许多经验和方法。如下所列。

(1) 理解标题真实含义。

对于译者, 尤其是那些不熟悉论文专业领域且不是作者本人的译者来说, 仔细解读原标题并合理安排和布局原标题的语言至关重要。应明确原标题的真实主题, 根据目标语标题的习惯和标准重新整合词汇, 并合理使用扩展和转换等必要的写作手段, 使标题在新的写作形式下最大限度地保留原词义和写作风格, 对于不是作者的译者来说, 最好是研究整篇文章, 了解文章的主要内容。当遇到高度专业化的文本或内容时, 有必要与原作者沟通, 以更好地理解标题所承载的文本内容。

(2) 充分了解跨语言标题的异同。

不同语言的科技论文标题既有相似之处, 也有不同之处。一般科学论文的标题具有明显的共性, 即语言简洁, 概括性强, 不应有太多复杂的修饰词。具有较强科学研究性和较高学术价值的科技论文, 其标题在内涵和外延上应符合术语化、规范化、格式化的特点。同时, 不同语言的标题也有不可忽视的显著差异, 尤其是在字数方面科学论文的英文标题不应该太长, 中国的科学论文写作标准和规范明确规定, 英文标题的字数一般不超过 10 个字, 中文标题的字数通常不超过 20 个汉字。

(3) 突出关键词。

在一个科技论文标题中往往只有两到三个或几个单词最为关键，其他词语仅起修饰和补充作用。因此，识别关键词将其安排在最为醒目的位置上便成为译者的首要任务。因语言表达习惯，不同语种标题中关键词的位置也有所不同，汉语标题中位于最后的位置常放置在题目中均为最为关键的词语，在英语标题中依据英语语言中“重点内容前置”的原则会将关键词人为地提至比较靠前的位置或句首，从而使得原题目及整篇文章的主旨内容得以突出再现。

(4) 谨慎使用缩写词及缩略语。

使用缩写词既可节省版面，符合标题对字数的严格要求，又能更好地表达文章的内容，因此在日常生活和科技交流中会经常遇到单词的缩写形式，但并非所有的读者都知晓某些缩略词的所指及意义，一些专业性很强的词汇缩写更是如此，如 TCT (Traffic Conflict Technique 交通冲突技术) 和 TNT (Turner Network Television 特纳电视网络公司)。所以，在论文的标题翻译中应尽量避免使用缩写词。

2.3.2 标题机译

对标题进行针对性的机器翻译的研究较少，目前有规则方法、实例方法、统计方法和神经网络方法四种。不同领域标题的翻译常具有不同的结构规则表达。邵建国采用规则和实例的方法研究公文标题的机器翻译^[43]，首先采用规则的方法限定了公文标题翻译的结构规则表达式，在此基础上补充了一个小型的公文标题平行语料库进行公文机器翻译的研究。苗洪霞等人针对航空领域的标题翻译利用统计机器方法搭建了一个机器翻译系统^[44]，首先对航空领域标题的特点进行分析，认为航空领域的标题大多为“基于+名词短语+的+名词短语/动词短语”的形式，在实际翻译时以短语作为整体处理，而不以词为单位进行处理。哈工大杨沐昀等人^[45]对科技文献标题的翻译做了研究，首先调研了科技文献标题的特点，例如字符长度，常用英文词，中文标题结构组成等，采用 web 检索获取译文，基本思想是对中文查询词进行启发性构造，然后使用搜索引擎检索包含中文查询词和其译文的双语网页，最后获得中文译文。2020 年 Etchegoyhen 和 Gete 利用图像分类系统 Iconclass 辅助艺术品标题的翻译^[46]，Iconclass 是一个描述艺术作品各种信息的库，通过利用从 Iconclass 中提取的文本信息置于编码器进行解码来提高自动生成的艺术品标题翻译的质量，结果表明神经机器翻译系统能够利用此元数据来提高艺术品标题的翻译性能。

由上述标题翻译研究可知，在对标题进行翻译研究时，主要思路都是先调查不同领域标题的语言学特点，然后对标题知识构建一些外部知识或者语料库直接做补充。例如针对公文标题的翻译研究者构建了一个公文标题的语料库，针对航空领域标题的翻译研究则是将航空标题的语法结构知识融入翻译过程，针对艺术品标题翻译则是利用了艺术品信息库来辅助翻译。因此对于本文研究

的科技文献标题的机器翻译来说，为标题找到最专业的外部知识补充是非常重要的。本文认为科技文献标题对应的摘要信息可以作为标题最专业的外部知识补充。

2.4 其他相关技术

2.4.1 大语言模型

大语言模型 (LLM) 是一种主要基于 GPT 技术实现的语言模型，其通过学习大量的文本数据来计算生成下一个词或下一段话的可能性，从而使计算机能够更好地理解和生成人类语言。OpenAI 公司在 2018 年提出生成式预训练 (GPT) 模型^[10]来提升自然语言理解任务的效果，正式将自然语言处理带入大语言模型预训练时代。预训练时代意味着利用更大规模的文本数据以及更深层的神经网络模型学习更丰富的文本语义表示。GPT 的出现打破了自然语言处理各个任务之间的壁垒，使得搭建一个面向特定任务的自然语言处理模型不再需要了解非常多的任务背景，只需要根据任务的输入输出形式应用这些预训练语言模型，就能够达到一个不错的效果^[47]。GPT “生成式预训练+判别式任务微调”的自然语言处理新范式，使得自然语言处理模型的搭建变得不再复杂。生成式预训练指在大规模文本数据上训练一个高容量的语言模型，从而学习更加丰富的上下文信息。判别式任务微调将预训练好的模型适配到下游任务中，并使用有标注数据学习此任务。

接下来将从两个方面介绍 GPT 模型。分别是上游的无监督预训练和有监督的下游任务微调。

(1) 无监督预训练

GPT 的整体结构是一个基于 Transformer 的单向语言模型，即从左至右对输入文本建模，如图 2.7 所示。




图 2.7 GPT 整体模型结构

GPT 的无监督训练是指在没有人工标注的标签数据的情况下进行训练。它

通过大规模的文本数据来预训练模型，并学习语言的概率分布和上下文关系，从而使模型能够生成具有语法正确性和语义连贯性的文本。在预训练阶段，GPT 通常采用自回归（Autoregressive）的方法^[48]，即通过预测下一个词语来学习语言模型。模型的输入是一个文本序列，通过 Transformer 的编码器层逐步预测下一个词语的概率分布。预训练过程中模型通过最大化预测的正确性来优化参数，从而使模型能够学习到文本的上下文信息和语言规律。

通过无监督训练，GPT 能够学习到语言的统计规律和语义信息，使得模型能够生成连贯且语义合理的文本。预训练的语言模型能够被应用于多种自然语言处理任务，如文本生成、机器翻译、对话生成等，并取得了显著的性能提升。

（2）有监督下游任务微调

在预训练阶段，GPT 利用大规模数据训练出基于深层 Transformer 的语言模型，已经掌握了文本的通用语义表示。微调（Fine-tuning）的目的是在通用语义表示的基础上，根据下游任务的特性进行领域适配，使之与下游任务的形式更加契合，以获得更好的下游任务应用效果。下游任务微调通常由有标注数据进行训练和优化。为了进一步提升微调后模型的通用性以及收敛速度，可以在下游任务微调时加入一定权重的预训练任务损失，缓解在下游任务微调的过程中出现灾难性遗忘（Catastrophic Forgetting）问题^[49]。在下游任务微调过程中，GPT 的训练目标是优化下游任务数据上的效果，更强调特殊性。因此，势必会对预训练阶段学习的通用知识产生部分的覆盖或擦除，丢失一定的通用性。通过结合下游任务微调损失和预训练任务损失，可以有效地缓解灾难性遗忘问题，在优化下游任务效果的同时保留一定的通用性。

对于本文的上下文信息获取问题，我们可以利用一些标题极其真实的上下文数据在大模型上微调一个特用于标题生成上下文的模型，微调后的模型既吸收了大语言模型强大的自然语言理解能力，又可以学习到由标题生成上下文的特征，具有很强的应用价值。

2.4.2 多编码器融合机制

基于上下文感知的机器翻译模型采用多编码器结构，通过多编码器对上下文信息进行额外编码进而将其信息融合到机器翻译系统来提升最终的机器翻译效果。融合方式包括解码器外部融合和内部融合两种方法^[50]。在多个编码器中，其中一个编码器用于编码当前源语言句子表示，另一个或多个编码器用于编码当前源语言句子的上下文表示。




图 2.8 外部融合




图 2.9 内部融合

外部融合模型^[51]指的是在解码器的外部进行信息的融合，之后再融合后的信息送入解码器内部进行解码。图 2.8 所示，当前源语言句子送入 Encoder_s 进行注意力计算得到隐层状态 H_s ，上下文送入 Encoder_c 进行注意力计算得到隐层状态 H_c ， H_s 和 H_c 经过多头注意力机制计算得到隐层状态 H_c' ， H_s 和 H_c' 在编码器端门控机制的作用下生成融合上下文的最终表示信息送入解码器。

内部融合模型^[52]指的是在外部的编码信息分别输送到解码器的内部进行信息融合。如图 2.9 所示，当前源语言句子送入 Encoder_s 进行注意力计算得到隐层状态 H_s ，再送入解码器端的编码-解码注意力网络模块 Attention_s 中得到隐层状态 H_s' ；上下文送入 Encoder_c 进行注意力计算得到隐层状态 H_c ，再送入解码器端的上下文注意力网络模块 Attention_c 中得到隐层状态 H_c' ； H_s' 和 H_c' 在解码器端门控模块进行注意力融合，在该基础上进行模型解码。

多编码器融合上下文信息的方法可以在翻译模型的解码阶段综合源语言句子的上下文信息对其进行更有效的解码，获得更好的译文。这个方法中上下文信息的选取非常重要，不好的上下文信息会弱化解码能力，使译文结果更差，因此对于本文研究的融合上下文信息的标题翻译，为标题选取的有效的上下文信息是关键。之后在有效的上下文信息基础上，采用多编码融合上下文信息的策略可以帮助提升标题翻译效果。

2.4.3 词嵌入生成器

词嵌入生成器是一种用已知字符嵌入或子词嵌入预测新词嵌入的工具，常用于生成开放词表的词嵌入^[53]，解决“预训练+微调”范式中下游任务的未登陆词（out-of-vocabulary, OOV）问题。最早的字嵌入生成器只根据词语内部结构的语素信息计算新词嵌入，通过对语素嵌入的直接求和^[54]、构建基于语素¹嵌入的 RNN 模型^[55]和提升语素嵌入的优先级^[56]等方法来预测新词嵌入。虽然基于语素的词嵌入生成方法可以充分利用词语的语言学特性，但很难处理像外语单词和人名这种语素信息不确定的词汇。之后基于字符的词嵌入生成方法被大量

¹ 语素是语言中最小的音义结合体，例如英语中的前缀后缀等。

研究,它超越语素的概念,直接对字符进行建模,可以生成语素信息不确定的词汇嵌入。一些基于字符嵌入的 RNN 语言模型^[57]、n 元字符计算模型^[58]、CNN 模型^[59]和 Bi-LSTM 模型^[60]等被研究。

无论是基于语素还是基于字符的词嵌入生成方法,早期的模型构建都是直接使用大量无标签数据进行训练。2017 年 Yuval P 等人^[61]首次对后处理阶段的词嵌入生成问题进行研究,即使用已训练好的词嵌入去预测新词嵌入问题。他们构建了 MIMICK 模型,通过预训练模型中已经训练好的词嵌入来监督学习字符嵌入,然后使用 Bi-LSTM 模型^[62]进行词向量的重构。在“预训练+微调”范式下,这种方法可以很好地解决下游任务中的未登陆词问题。随着子词(subword)技术在语言模型中的应用,由子词嵌入生成新词嵌入的方法进入研究视野。Bojanowski 使用子词嵌入来提升单词嵌入效果构建了 fastText 模型^[63]。这个模型可以有效解决未登录词问题,但仍需在大量数据上训练获得。如何利用预训练模型的子词嵌入生成新词嵌入成为研究的重点,Zhao 认为一个单词可看成是子词词袋(Bag of subword),提出 BOS 模型,其在一定范围内对单词进行子词解析,从子词中构建每个单词的词嵌入来训练词嵌入生成器^[64]。Sadsaki 将注意力机制引入基于子词的词嵌入生成器,通过共享嵌入和自注意力机制构建基于子词的词嵌入生成器^[65]。这种方法既保证了词嵌入生成器对未登录词的适用性,同时又节省了词向量的存储空间,大大提高了词嵌入生成器的适配性。

之前的研究大多只针对某个固定下游任务的未登录词的嵌入问题,没有将自然语言处理领域微调阶段的未登陆词问题当成一个统一的问题进行研究。2021 年 Liu Xin 等人^[66]提出一种普适于“预训练+微调”范式下的即插即用的词嵌入生成器方案。他们利用子词和超词概念¹,将预训练词表中的词进行随机拆分重组产生大量新词,采用基于位置感知的注意力方法对新词嵌入编码并进行蒸馏学习训练,最终达到覆盖任何下游任务未登陆词的目的。基于位置感知的注意力编码方法充分考虑新词与其在预训练词表中子词和超词的语义信息和不同位置语素信息的影响,构建公式如下:

$$G(w) = \frac{1}{|S_m(w)|} \sum_{w' \in S_m(w)} \alpha(w') E(w') \quad (\text{公式 2.2})$$

$$\alpha(w') = \frac{\exp(W_r E(w'))}{\sum_{w' \in S_m(w)} \exp(W_r E(w'))} \quad (\text{公式 2.3})$$

式中, w' 表示新词 w 的子词或超词且构建集合 $w' \in S_m(w)$, $E(w')$ 为 w' 在预训练模型中的嵌入表示, $G(w)$ 为要构建的新词嵌入编码。 $W_r \in R^{6 \times d}$ 是需要训练学习的参数。

他们在原预训练模型基础上采用蒸馏学习^[67]的方法训练词嵌入生成器,即

¹ 如果模型中输入词为完整单词,则组成它的词为子词,例如“er”,“sing”,“sin”是“singer”的子词。如果一个词为

在预训练模型基础上多训练一层源语言新词嵌入和目标语言新词嵌入。为达到新词嵌入训练的目的，将原预训练语料的句子（分词和 BPE 之后的）进行随机分割，通过固定预训练参数来训练新词嵌入。例如训练句子“nothing I could have imagined”这句话，它在预训练模型中的子词分割形式为“nothing, I, could, have, ima, gine, d”，我们对其进行重新分割为“noth, thing, I, could, have, imagine, d”，后者产生的新词“noth”，“thing”，“imagine”由于不在原预训练词表中，故其词嵌入编码可由词嵌入生成器产生。训练时的损失函数表达式如下：

$$\mathcal{L}_d(s^p, s') = \frac{1}{|s|} \sum_{w \in s} \|h^p(w) - h'(w)\| \quad (\text{公式 2.4})$$

并指定一个超参数 λ 来量化 $L(\cdot)$ 和 $L_d(\cdot)$ 的影响，实验中将其设为 0.5。

$$\mathcal{L}(s^p, s') = \mathcal{L}_p(s') + \lambda \mathcal{L}_d(s^p, s') \quad (\text{公式 2.5})$$

上述两式中， s^p 表示一条训练语料 s 经预训练模型的嵌入表示， s' 为语料 s 重新分割后合并新词嵌入后的表示， w 表示训练语料 s 中的每个完整单词。

在微调阶段，通过词嵌入生成器中不同粒度的子词迁移可以弥合预训练和微调的子词差异问题，因此即插即用的词嵌入生成器方案可以有效解决多个下游任务的未登陆词问题。其在机器翻译领域可以用来解决多个垂直领域的机器翻译问题，例如在俄汉预训练模型词表中，由于数据分布情况比较均衡，一些词语出现频率并不高，因此经 BPE 之后常常会被分成出现频率较高的子词的组合。例如俄文单词“телескопы”（中文“望远镜”），在对预训练数据进行 BPE 后它会被切分成子词“теле”（中文“远处”）和子词“скопы”（中文“观看”）。因此在预训练模型词表中并不直接存在“телескопы”这个词，而是存在“теле”和“скопы”两个子词。若直接对俄文词汇“телескопы”进行翻译，可能直接被翻译成“远远看”。但在天文学领域的俄汉训练数据中，由于“телескопы”这个词汇出现频率会很高，因此 BPE 之后并不会被分割成子词的形式，依旧保留原来的形式。所以在对天文学领域的数据进行微调时，这个词汇不在原预训练模型词表中，它会成为一个未登陆词无法被正确翻译。即插即用的词嵌入生成器的存在使得预训练模型的源语言新词嵌入层存在“телескопы”这个词的嵌入，因此在微调时这个词可以被很好的训练，最终微调模型能够给出其正确译文。同理，对于目标语言的未登陆词问题也是一样。

由上述词嵌入生成器的调研可以得知，词嵌入生成器是解决“预训练+微调”范式下未登录词问题的一种非常好的方法。即插即用的词嵌入生成器方案中，引入注意力机制的编码方法和蒸馏学习的训练方式使得词嵌入生成器对于新词具有更好的嵌入表示能力。同时不同粒度子词的迁移方式不仅可以覆盖下游未登陆词，同时也可以增进预训练模型与微调模型的联系，减少暴露偏差。对于本文研究的科技文献标题的俄汉翻译来说，科技文献标题含有较多术语，在使用基于枢轴语言的迁移学习方法对其微调时，上下游的子词差异会造成大量未

登陆词，而且在迁移学习过程中会存在信息传递误差导致输入输出词不匹配。本文认为词嵌入生成器中不同粒度的子词迁移过程可以很好的解决基于枢轴语言的迁移学习方法中的这两个问题。如何为基于枢轴语言的迁移学习模型设计词嵌入生成器将是本文研究的重点。

2.5 小结

本文研究目标是科技文献标题的俄汉翻译。针对该研究目标以及本章中各类相关研究，梳理本文的研究思路如下：

从短文本翻译的角度，在翻译模型上神经机器翻译虽然不一定保证总能优于统计机器翻译，但是神经机器翻译是机器翻译进展的主流方向，因此本文仍然选择神经机器翻译模型作为研究框架。已有的短文本翻译方法中，多采用融合外部知识的策略提升翻译效果。对于标题机器翻译研究，引入其上下文信息做外部知识补充是提升其翻译效果的一种方法。已有的标题机器翻译研究主要聚焦在通用领域，并为涉猎科技文献标题这样具有专业性术语的领域。因此如何为科技文献标题获取专业性上下文信息是研究的重点。虽然利用论文库和网络资源可以获取一部分标题的上下文信息，但是不能保证对于任意标题都能检所得摘要上下文，而大模型拥有广泛的知识，利用大模型来获取标题的专业性上下文信息也是一个可行且有益的思路。

从迁移学习低资源翻译的角度来看，本文研究为俄汉机器翻译，俄汉双语数据少导致直接训练效果并不理想，但由于俄英和英汉之间存在着大量的平行语料，因此以英语作枢轴语言，直接对俄汉低资源机器翻译采用基于枢轴的迁移学习方法进行模型搭建最为合适，可有效提升其翻译效果。枢轴迁移方法自身存在着信息传递误差问题，对于本文研究的科技文献标题翻译来说，由于存在众多领域词汇，又在微调阶段存在着大量未登陆词问题。即插即用的词嵌入生成器方案中不同粒度子词的迁移过程可以很好地解决这两个问题，因此如何为基于枢轴语言的迁移学习模型设计词嵌入生成器是本文需要研究的内容。

本文致力于俄汉低资源机器翻译模型提升，改善科技文献标题更为专业化翻译，因此从下述三方面开展：

（1）获取专业的标题上下文信息。

科技文献标题中包含大量专业术语。因为一些术语在不同领域的含义不相同，所以仅靠输入标题的机器翻译，所得结果准确性比较难把握。为了更准确地进行术语翻译实现标题翻译效果的提升，本研究构建三种标题上下文信息的获取机制，分别是论文库搜索机制，web 检索机制和大模型生成机制，最终获取标题的专业性上下文信息。

（2）提升俄汉低资源翻译模型。

基于枢轴的迁移学习方法自身存在着信息传递误差问题，同时又属于“预

训练+微调”的范式，微调阶段的词表需要继承自上游模型，对俄汉数据尤其是俄汉科技文献标题数据进行微调时会出现大量未登陆词，影响翻译质量。本文从词嵌入生成器不同粒度子词迁移过程受启发，提出基于枢轴词嵌入生成器的机器翻译模型，将词嵌入生成器融入到以枢轴语言为基础的迁移学习中，弥合上下游词汇异，提升机器翻译模型的鲁棒性和开放性。

（3）构建融合上下文信息的标题翻译模型。

获取到专业性的标题上下文信息后，利用枢轴词嵌入生成器机器翻译模型得到源语言的标题初始译文后，通过多编码器策略构建融合机器翻译模型来融合标题上下文信息和初始译文，提升科技文献标题的机器翻译质量。

3 科技文献标题上下文抽取研究

3.1 引言

短文本机器翻译最大的问题是文本太短缺乏有效的上下文信息。在神经机器翻译中通常引入被翻译文本的前一句或者后一句信息来作为上下文对其做补充。有效的上下文信息可以增强翻译效果获得更加准确的译文，无效的上下文信息则会误导翻译模型导致很差的翻译效果。因此上下文信息的有效性直接影响了翻译模型的性能。

对于科技文献的标题来说，最有效最可行的上下文信息便是其所在科技文献的摘要，如图 3.1 所示。摘要是对标题的简单论述，也是对论文内容的概括总结，可以很好地补充标题的隐藏信息。所以本文引入摘要作为标题翻译的上下文信息补充。




图 3.1 科技文献标题摘要示例

本文研究对象为俄语科技文献的标题。笔者所在课题组的自有俄语论文数据库中的文献资源有限，无法保证任何一个标题对应的真实摘要都在库中，因此通过网络资源获取摘要信息是一种可行的方法。当这两种方法仍然无法获取到文献摘要时，需要探究第三种标题上下文信息抽取方法。2022 年 11 月 ChatGPT 的发布掀起了全球大模型学习的狂潮，之后各种大模型相继推出，相应的技术尤其微调技术不断发展。大语言模型庞大的知识储备和强大的自然语言的推理能力可以帮助俄语科技文献标题获取到类似摘要的上下文信息。

本章构建了三种获取标题上下文信息的机制，分别是自有论文库检索机制、web 检索机制和大模型生成机制。其中在大模型生成机制以科技文献标题的真实摘要作为模板，对大模型进行有监督地下游任务微调，通过设计不同提示词

(prompt) 和参数最终训练一个由科技文献标题获取摘要的生成语言模型。

3.2 抽取方法

如图 3.2 所示，标题上下文信息获取机制分为三个部分，分别是自有论文库检索、web 检索和大模型生成。该机制的输入为科技文献俄语标题，首先通过查询语句向自有论文库检索，如果检索失败则通过 BingAPI¹向网络资源进行检索。如果前两种方法都获取不了摘要信息，那么最后通过大模型机制生成摘要内容，输出为该俄语标题对应的俄语摘要信息。




图 3.2 标题上下文信息获取机制

3.2.1 论文库查询机制

本文所用的俄语论文数据库由笔者所在课题组通过各个渠道收集的俄语论文组成。数据库共收录有俄语论文约 50 万篇，论文研究内容横跨医学、材料、电子等多个自然科学领域以及部分社会科学领域。论文数据采取关系型数据库 MYSQL 进行储存^[68]，使用 SQL 语句进行查询即可得标题对应的摘要信息，如式 3.1 所示：

$$\text{select abstract from rupaperdata where title = 't';} \quad (\text{公式 3.1})$$

式中 rupaperdata 为俄语论文库名称，abstract 和 title 为论文数据的字段，t 为我们所查询的俄语标题。

¹ <https://www.microsoft.com/en-us/bing/apis/bing-web-search-api>

3.2.2 Web 检索机制

由于自有的俄语论文库收录论文数量有限，对没有收录进去的论文根据其俄语标题查询不到摘要信息。本文借助丰富的网络资源构建 Web 上下文检索机制，通过设计一系列检索规则来获取准确的摘要信息。Bing API 的网络检索流程如图 3.3 所示。首先进行 API 检索的参数设置，语言设置为俄语，关键字为俄语科技文献标题，结果数量设置为 10，取搜索结果的前十条，API 密钥由 Microsoft 的 Bing 平台申请所得。参数设置好后，即向 Bing 平台发出检索请求，会返回十条搜索结果，如果返回结果为空，则说明此条标题在 Bing 平台检索失败，摘要信息无法获得。如果检索结果存在，则进一步进行检索结果的过滤，过滤掉网页中不存在摘要字段的搜索结果。如果过滤之后剩余的检索结果为 0，则也说明此条标题在 Bing 平台检索失败，摘要信息无法获得。如果检索结果不为 0，之后继续判断剩余检索结果中摘要字段对应信息是否为空，如果为空则将此条检索结果过滤掉。全部判断一遍后如果仍存在合格的检索结果，则选择排在第一位置的搜索结果的摘要字段信息作为此标题的摘要信息，否则说明此标题对应的摘要信息不能通过 Web 检索机制检索出来。




图 3.3 基于 Web 的标题上下文检索流程

3.2.3 大模型生成机制

自有论文库查询机制和 Web 检索机制都无法获取摘要上下文的俄语论文标题采用大模型生成机制。大型语言模型能够对标题进行有效的感知和理解，利用其海量数据提供较为专业的上下文信息。

利用大语言模型生成标题对应的摘要信息有两种方法，一种是直接输入提示词和标题，让模型根据输入的内容直接推理出摘要信息。例如，想生成俄语标题“СТВОЛОВЫЕ КЛЕТКИ СЕРДЦА: ФАКТ ИЛИ ФАНТАЗИЯ?（心脏干细胞，事实还是幻想？）”的摘要信息，可以向大模型直接输入如图 3.4 中的示例即可。其中提示词的设计是人为的，可以向同一个生成任务下达不同语句不同语言的提示词^[69]。




图 3.4 大模型直接推理提示词（prompt）示例

大语言模型的推理质量取决于模型的训练数据和容量。为保证模型生成摘要的质量，本文用在语言模型上进行下游任务微调的方法构建基于大模型的标题上下文生成机制。如图 3.5 所示，本文在 Chatglm 大模型^[70]基础上采用 ptuning_v2^[71]的大模型高效微调方法进行微调。模型的微调数据为文献的标题和摘要数据，在微调过程中，大语言模型只训练 prompt 部分的参数，其他的参数保持不变。由标题摘要数据上对大模型进行精调获取的摘要生成模型，既能继承大语言模型强大的自然语言处理理解和生成能力，又能学习到标题生成摘要的任务领域特征，可以提升摘要生成质量。




图 3.5 微调大语言模型方法

3.3 实验

本章对标题上下文的 web 检索机制和大模型生成机制两部分分别进行实验验证。web 检索机制从检索效率和检索质量两个方面进行评价。大模型生成机制分别设计直接推理生成和微调实验。两种机制都用 Rouge-1 和 Bleu4 指标来评价获取的摘要信息的专业性。

3.3.1 实验数据

(1) 数据来源。

对于标题上下文的 web 检索机制，本文从自有论文库中随机抽取 1100 篇俄语论文标题和其对应的真实摘要数据，其中标题数据用来进行 web 检索，真实的摘要数据用来对检索结果的质量进行评价。对于标题上下文的大模型生成机制，本文从自有论文库中调用 25 万篇俄语论文的标题和其真实摘要数据用于大模型微调实验和提示直接推理实验。

(2) 数据预处理。

在标题上下文的 web 检索机制中，俄语论文的标题数据用于网络检索，保持其原来格式有助于准确定位目标文献进而实现摘要信息的检索，提升检索质量。所以不对标题的大小写标点符号进行规范化处理。同样，网络检索到的摘要信息也是保留其原本格式，因此摘要数据也不对其大小写标点符号等信息进行规范化处理。这里只进行语种识别和空白信息过滤操作。通过 python 工具包 pylangid¹进行标题和摘要信息的语言识别，保留摘要和标题都为俄语的数据，避免非俄语数据混杂。之后再过滤掉数据中标题或摘要为空白的数据。

在标题上下文的大模型生成机制中，俄语论文的标题和摘要数据主要用于微调，保持格式统一可以提升训练数据质量，所以对其进行规范化处理是有必要的。本文采用 mosesdecoder²数据预处理工具对所有文本数据进行非法字符过滤、标点符号规范化等操作，然后进行语种识别和空白信息过滤操作。由于俄语科技文献的标题大小写并不统一，有的文献标题全部字符大写，有的只首字符大写，为了提高大模型的微调效果本文将标题信息一律做首字符大写的转换操作。模型的训练数据需要有长度控制，否则会影响训练效果。但科技文献论文中的一些摘要数据有时候会分好几段字符数过多，且这种情况下后几段文本大多是讨论文献细节问题，对标题的补充性不强且给模型训练带来了很大不方便。因此本文在预处理阶段对摘要字符过多的数据进行文本截取，对拥有多段文本摘要只截取其第一段作为摘要数据，对于摘要文本长度超过 500 字的只截

¹ <https://github.com/hamidzafarte/pylangid>

² <https://github.com/moses-smt/mosesdecoder>

取前 500 字符。最后进行数据集划分,从处理后的数据中各抽取 2000 条标题摘要数据分别做微调模型的开发集和测试集。其中测试集标题和摘要数据也用于提示直接推理的实验。

对两个机制的实验数据进行预处理后的数据规模如表 3.1 所示。

表 3.1 预处理后数据规模

实验模块	数据	数据规模 (篇)
web 检索机制	俄语标题和摘要	1000
大模型生成机制	俄语标题和摘要	240000

3.3.2 实验设置

本章对标题上下文的 Web 检索机制和大模型生成机制的实验设置分别进行介绍。

(1) 标题上下文的 Web 检索机制。

标题上下文的 Web 检索机制实验的检索工具为 Bing API,检索数据为 1100 条俄语文献标题,语言参数设置为俄语。使用 Python3.9 版本编写代码,检索流程如 3.3 节中的图 3.3 所示。

本实验从检索率和检索质量两部分来评价 Web 检索机制。检索率是指任意一个输入的论文标题其能被检索到其摘要信息的概率。本文设计评价指标 R_e 来表示:

$$R_e = \frac{\text{能检索到摘要结果的标题个数}}{\text{检索标题的总各个数}} \times 100\%$$

检索质量用来评价所检索出来的摘要信息与真实摘要信息是否相关。如果检索出来的摘要信息就是此标题真实的摘要信息,则说明此上下文检索机制的检索质量高。本章实验采用 ROUGE 和 BLEU 指标对摘要信息的检索质量进行评估。

(2) 标题上下文大模型生成机制。

标题上下文大模型生成机制的实验在 Linux 服务器 CentOS 7.6.1810 系统上进行,Python 版本为 3.9.0,PyTorch 版本为 2.0.1,由于微调阶段对 Transformer 工具包版本有要求,因此环境部署的 Transformer 工具包版本为 4.27.1。使用的大语言模型为清华开源的 Chatglm-6b¹,使用的计算资源为 2 块 16G 的 Tesla V100 GPU 显卡。在提示直接推理实验中,通过提示词加俄语标题的输入方式直接进行大模型的摘要推理生成。推理所采用的数据为 2000 条划分好的标题

¹ <https://huggingface.co/THUDM/chatglm-6b>

测试集，本文简单地采用三种语言表达的同一含义 Prompt 和不用 prompt 的直接输入四种方法来进行摘要的推理生成，探究 prompt 对模型推理的影响，实验中设计的 prompt 和摘要输出长度设置如表 3.2 所示。对于大模型微调实验，本文采用划分好的标题和对应摘要的训练集，开发集数据进行微调，推理阶段采用与基于提示的推理实验一样的 2000 条测试集进行推理，推理使用的 prompt 与微调阶段训练的 prompt 保持一致。微调阶段的 prompt 设置和参数设置如表 3.3 所示。

表 3.2 大模型直接推理的实验设置

参数	设置
Prompt（提示）	○ 没有提示
	① 给出一下俄语标题对应的摘要
	② Please give a summary of the following Russian titles.
	③ Пожалуйста, дайте резюме, соответствующее следующему русскому заголовку（请提供与以下俄文标题相对应的摘要）
输出文本长度控制	500 字符

表 3.3 大模型微调参数设置

参数	设置
Prompt	Give a summary of the following Russian titles
Learning rate 学习率	0.0001

3.3.3 实验结果

标题上下文 web 检索机制的实验对 1000 条俄语科技文献的标题依据文本构建的检索机制进行摘要信息检索，表 3.4 为检索出摘要结果的数据统计。表 3.5 是对检索出的 237 篇摘要与其对应的真实摘要进行的检索质量评估。评估指标选取 Bleu-4 和 Rouge-1。

表 3.4 web 检索机制的检索率

检索对象	总检索数	检索出结果的数量	检索率
俄语标题	1000	237	23.7%

表 3.5 web 检索机制质量评估

评估对象	数量	Bleu-4	Rouge-1
检索出的摘要	237	91.73	93.47

由表 3.4 统计的标题上下文 web 检索结果可知，输入 1000 条俄语文献标题，会有 23%左右的标题可以通过本章构建的 web 上下文检索机制获取其摘要信息。说明了本文利用网络资源获取摘要信息的方法是可行的，是能够获取到一定规模的标题上下文信息的。由表 3.5 中对标题上下文 web 检索结果的评估打分可以看到 BLEU 打分和 ROUGE 打分都非常高，接近满分一百，说明本文通过 web 检索机制检索到的 237 篇摘要信息与真实的摘要信息文本几乎完全相同，也证明了本章构建的 web 上下文检索机制不仅能够检索到摘要信息，还能够检索到真实的摘要信息。因此可得本文构建的标题上下文 web 检索机制可以获取一定规模的标题的摘要信息，能够提供专业的上下文信息。

标题上下文的大模型生成机制实验在 24 万标题和摘要数据上展开。在提示直接推理实验中本文使用 2000 条标题测试数据加上四种 prompt 方式作为输入进行大模型的直接推理，用 Bleu-4 和 Rouge-1 两个指标来衡量推理生成的摘要与测试集对应的真实摘要的差距。在大模型微调的实验中首先进行摘要生成模型的微调，在训练到 0.2epoch 时，模型在 24 万摘要数据上达到收敛，停止训练。之后同样采用 2000 条标题测试集对微调好的模型进行推理，通过 Bleu-4 和 Rouge-1 两个指标来判断摘要生成效果。表 3.6 记录了标题上下文的大模型生成机制的实验结果。

表 3.6 大模型生成机制质量评估

实验	Prompt	Bleu-4	Rouge-1
提示直接推理	无	1.14	1.27
	给出一下俄语标题对应的俄语摘要	3.09	4.36
	Give a Russian summary of the following Russian titles.	3.30	3.77
	Пожалуйста, дайте резюме, соответствующее следующему русскому заголовку	2.89	3.01
微调生成	Please give a summary of the following Russian titles.	43.45	89.46

由表 3.6 可知，对于本文调用的 chatglm-6b 模型直接输入俄语标题进行摘要推理的 bleu-4 和 rouge-1 值接近于 0，说明直接推理生成的摘要效果非常差；其次引入提示词后生成的摘要结果的评估分数要比不引用提示词的有所提升，说明提示词在大模型推理阶段有着非常重要的意义，可以提升大模型的推理性能，帮助提问者获得想要的信息。但由实验中的三个含义相同但语言不同

的提示词进行推理的结果来看,会发现提示词的稍微变动都会大幅度影响模型的推理效果。其中用英文和中文做提示词效果相对较好,用俄语提示词效果最差。其原因可能是由于 chatglm-6b 大模型的训练语料的语种构成问题,使得大模型更能理解中英文的提示词。从微调生成实验结果可以看到,微调后的模型生成的摘要质量显著提升, Bleu-4 值达到了 43.45, Rouge-1 值更是达到了 89.46,说明生成的摘要和真实的摘要内容上已经有很强的相关性,从利用微调模型生成的摘要可以对科技文献标题做有效的上下文的补充。同时也验证了本文提出的基于大模型进行标题上下文信息抽取方法的可行性。

3.4 小结

本章节对科技文献标题的上下文信息获取进行研究,首先明确科技文献的摘要是其标题最专业的上下文信息。之后围绕如何根据俄语标题获取其对应摘要上下文信息进行了分析,构建了从自有论文库检索机制、web 检索机制和大模型生成机制三种标题上下文获取途径。首先通过查询语句向自有论文库检索,如果检索失败则通过 BingAPI 向网络资源进行检索。如果前两种方法都获取不了摘要信息,那么最后通过大模型机制生成摘要内容。大模型生成机制中采用大模型预训练加 P-Tuning 的方式。经实验验证 web 检索机制可以有效又准确地获取到标题的摘要信息,大模型生成机制经过真实的标题和摘要数据训练具备根据输入的标题和提示词生成一个与标题上下文极为关联且专业的类似摘要的上下文信息的能力。本章对标题上下文获取途径的构建有助于在已有资源内快速获取标题的上下文信息,为之后第五章的融合上下文信息的标题机器翻译研究做好准备。

4 基于枢轴词嵌入生成器的俄汉机器翻译研究

4.1 引言

在基于枢轴语言的迁移学习方法中,相关研究提出了分步学习,枢轴适配器和跨语言编码器等改进策略。无论是哪个策略,都是预训练加微调的模式。该模式最终的源-目标翻译模型中的源语言编码器与目标语言编码器的初始化参数分别来自两个预训练模型,其中源语言编码器的初始化参数是在源-枢轴预训练中与枢轴语言的解码器一起训练而成,而非目标语言解码器;目标语言解码器的初始化参数是在枢轴-目标预训练中与枢轴语言的编码器一起训练而成,而非源语言编码器。因此最终模型的源语言编码器与目标语言解码器进行组合进行参数初始化时,会存在参数不匹配导致信息传递误差。同时微调阶段必然存在着未登录词的问题,对于俄汉科技文献标题的翻译具有很大挑战。

针对上述问题,受词嵌入生成器不同粒度子词迁移过程启发,本章在分步学习和跨语言编码器改进策略的基础上继续改进,从缓解迁移前后的子词差异解决未登陆词问题和细化子词粒度来增进编码器和解码器信息传递的角度出发,提出基于枢轴词嵌入生成器的机器翻译模型,将词嵌入生成器融入到以枢轴语言为基础的迁移学习中。如图 4.1 所示,整个模型分为跨语言预训练、枢轴-目标预训练、微调和枢轴词嵌入生成器四部分,枢轴词嵌入生成器又包括跨语言词嵌入生成器和目标语言词嵌入生成器。




图 4.1 基于枢轴词嵌入生成器的模型架构

本模型既实现了参数的迁移 (Parameter transfer) 又完成了子词嵌入的迁移 (Embedding transfer)。词嵌入生成器可以对已有词汇进行拆解组合,为新词生成词嵌入。将其融入以枢轴语言为基础的迁移学习中,一是可以帮助微调阶段获取大量新的源词嵌入和目标词嵌入,缓解子词差异解决微调阶段的未登陆

词问题,其中跨语言词嵌入中获取的枢轴语言的新词嵌入(英语)可以更为便利地处理标题文本中的英文词汇,有助于处理更丰富的语义信息,使机器翻译系统具备更强的鲁棒性。二是词嵌入生成器以细化子词粒度的方式可以在分步训练策略中进一步联结编码器和解码器的信息传递,增进微调后的低资源翻译效果。

本研究中神经机器翻译架构采用最基础的 Transformer 模型,在预训练和微调(Pre-train & Fine-tune)的范式下^[72],力求获得更好的翻译效果。

4.2 模型

如图 4.1 所示,整个模型分为跨语言预训练、枢轴-目标预训练、微调和枢轴词嵌入生成器四部分,枢轴词嵌入生成器又包括跨语言词嵌入生成器和目标语言词嵌入生成器。其中,跨语言预训练旨在使用源-枢轴平行语料训练一个具有跨语言特性的跨语言预训练模型,之后在这个模型上继续训练跨语言词嵌入生成器,训练完成后的模型会比原预训练模型在编码器和解码器的结构上分别多一个词嵌入层,生成跨语言编码器,其参数用于枢轴-目标预训练阶段的编码器参数初始化和微调阶段的编码器参数的初始化。经过编码器参数初始化后使用枢轴-目标的平行语料进行枢轴-目标预训练,整个训练过程中要对编码器上的所有参数进行冻结,只保持解码器参数变化。接着在枢轴-目标预训练上继续训练目标词嵌入生成器,训练完成后枢轴-目标预训练模型解码器上会有一个针对目标语言的词嵌入层,生成目标语言解码器,其参数用于微调阶段目标解码器参数的初始化。在微调阶段,源端编码器和目标端解码器的初始化参数来自于前两个阶段训练而成的跨语言编码器和目标解码器,通过源-目标平行语料的微调训练得到最终的源-目标机器翻译模型。

4.2.1 跨语言预训练

跨语言预训练不同于枢轴迁移中通常的源-枢轴语言预训练模型,其编码器具有跨语言特性,能够对枢轴语言和源语言在同一数学空间进行建模。这里引入一个由枢轴语言到枢轴语言的自编码机制实现跨语言性。自编码器(Autoencoder)是一种无监督学习算法^[73],它可以将输入数据压缩成低维表示,同时尽可能地保留原始数据的信息。自编码器的目标是最小化重构误差,即输入数据与自编码器生成的重构数据之间的差异。自编码器通常由两部分组成:编码器和解码器。如图 4.2 所示,编码器部分负责将输入压缩成潜在空间表征,用 $h = f(x)$ 表示编码函数;解码器部分通过这种表征来重构输出,用 $r = g(h)$ 表示解码函数。整个自编码器可以用 $g(f(x)) = r$ 来表示。




图 4.2 自编码结构

跨语言预训练中编码器端输入源语言和枢轴语言的两种语言句子，它们都被只输出枢轴语言的共享解码器进行处理。这种训练方式使得无论输入语言如何编码器都可以在共享空间中生成表示。在自编码阶段只是单纯的复制输入不足以学习数据领域的复杂结构，本研究加入了降噪自编码器（Denoising Autoencoder），它通过引入人工噪音对输入的源语言句子进行破坏^[74]。为了重构“干净”的句子，它会在句子的语言学结构信息和单词的次序上有更多的编码信息。本文使用的噪声类型^[75]如下：

- 随机删除一些词语，删除概率用 p_{del} 表示。
- 用<BLANK>随机取代一些单词，取代概率用 p_{rep} 表示。
- 固定距离内随机交换单词位置，范围用 d_{swa} 表示。

其中的三个参数分别设定为 0.1、0.1、3。

4.2.2 枢轴-目标预训练

枢轴-目标预训练时继承分步训练的改进策略，编码器信息沿用跨语言预训练中的编码器信息。并且训练时进行冻结，只优化更新解码器参数，编码器参数保持不变，同时进行目标语言词嵌入生成器的训练。最后再进行参数迁移和微调。如果不进行冻结，编码器参数继续保持更新，会出现编码器只具有枢轴语言信息的编码能力而遗忘了源语言信息编码的能力的现象。这种冻结的方式可以在训练中使目标语言解码器适应具有源语言编码能力的编码器的输出，使源语言编码器信息和目标语言解码器信息联系的更加紧密。

4.2.3 枢轴词嵌入生成器

本章将词嵌入生成器引入基于枢轴语言的迁移学习中，研制了枢轴词嵌入生成器，其又分为跨语言词嵌入生成器和目标语言词嵌入生成器。

（1）跨语言词嵌入生成器。

跨语言词嵌入生成器包含三个模块，如图 4.3 所示，分别是新词生成模块，语言识别模块，新词嵌入编码模块。新词生成模块为了满足下游语料直接初始化任何新词的需求，避免模型重新训练浪费时间。语言识别模块帮助准确识别出不同语言的词，避免嵌入大量无效的新词。新词嵌入编码模块帮助新词的编码要尽可能准确体现出相关词的语义信息。

新词生成模块借用跨语言预训练模型和它的词表进行词嵌入生成器的训练，跨语言预训练模型的词表中包含着大量的词汇，通过对其进行随机的拆分和组合可以产生更多的新词汇，基本能够达到覆盖下游语料的目标。在进行词汇组合时，一些跨语言预训练词表里的子词会组合成新词，例如俄文词汇“Англий”（中文“英国”）和“Ский”（中文“语言”）会在词嵌入生成器中组合成“Английский”（中文“英语”），其中“Англий”和“Ский”就是新词“Английский”的子词；在进行词汇拆分时，一些跨语言预训练词表里的超词会拆分成新词，例如英文词汇“nothing”拆分成新词“no”和“##thing”，其中“nothing”就是“no”和“##thing”的超词。




图 4.3 跨语言词嵌入生成器工作流程

在跨语言词嵌入生成器使用预训练词表的词汇组合生成大量新词的过程中，引入一个具有语言识别功能的模块，避免生成由俄语和英语组合成的大量具有无效语义的新词。例如在进行预训练词表词汇的随机组合时，会出现“ima”和“Ский”组合成“имаский”这种情况，这些新词不表示任何语义信息，在俄汉的下游语料微调中没有任何用处。所以通过语言识别功能，对要进行组合的词进行识别，只有在这些词是同一种语言的情况下才可组合成新词。

跨语言词嵌入编码模块同样采用基于位置感知的注意力方法对新词嵌入编码。俄语和英语语料中的词汇会有两种词嵌入，一种是跨语言预训练的词嵌入，一种是跨语言词嵌入生成器得到的新的词嵌入，在处理语义信息时因编码信息的差异两种词嵌入不能共享相同的隐空间，在内层的空间状态不能保持一致。为了缩小这种差距，同样使用知识蒸馏的方法进行训练。

由于跨语言预训练中源端包含了源语言词汇和枢轴语言词汇，编码器端的词嵌入生成器也将许多英语词语进行拆分重组，保留了很多嵌入层原来没有的英文新词的嵌入信息，在枢轴-目标预训练阶段这些英文新词也可以为枢轴-目标语料的预训练提供更多便利。训练数据中源端输入词语粒度的丰富会增强目标端解码器的解码效果，提升翻译系统的鲁棒性。

(2) 目标词嵌入生成器。

目标词嵌入生成器只需要对枢轴-目标预训练的目标语言汉语进行词嵌入生成，不像跨语言词嵌入生成器需要同时对英语和俄语进行词嵌入生成，因此在词嵌入生成器的构建阶段不需要语言识别模块，只由两部分组成，新词生成模块和新词嵌入编码模块。如图 4.4 所示，新词生成模块与跨语言编码器一样采用随机拆分组合模式，新词嵌入编码方式采用于位置感知的注意力方法。

目标词嵌入生成器的训练过程与跨语言词嵌入生成器一样，都是采用知识蒸馏的方法，减小损失函数的值。但目标词嵌入生成器的训练过程中编码器部分的参数是属于冻结状态，只对解码器端的参数进行优化，其编码器参数继承于跨语言阶段的跨语言编码器，跨语言词嵌入生成器也被一同继承而来。在训练过程中，英语语料通过跨语言词嵌入生成器嵌入到模型中进行训练，目标端解码器可以获得更多不同粒度的英语词汇信息，经过训练可以获得更多英译汉的信息，提升目标端解码能力，有助于下游微调任务的学习。




图 4.4 目标词嵌入生成器工作流程

4.3 实验

本节对基于枢轴词嵌入生成器的机器翻译模型进行实验，首先搭建基于分步训练，枢轴适配器，跨语言编码器等改进策略的基于枢轴语言迁移学习的机器翻译强基线系统，之后分别在俄汉通用数据、俄汉科技文献标题数据以及这两者的混合数据上进行微调测试这些模型对科技文献标题的机器翻译能力，利用 BLEU 指标为模型打分。

4.3.1 数据处理

这里使用的数据集有俄英数据集，英汉数据集和俄汉通用数据集和俄汉科技文献标题数据集以及构建的五组俄汉科技文献标题测试集的译文集。其中俄汉标题数据从自建论文库收集构建，其他数据集由 WMT2022¹所提供的语料库收集而来。俄汉科技文献标题测试集由五个不同人为翻译的结果所构建。对五种平行语料进行的数据预处理流程如下所列：

(1) 文本清洗。

¹ <https://statmt.org/wmt22/translation-task.html>

使用 HarvestText¹工具中的 clean_text 方法进行乱码过滤,去掉网址 URL 链接、html 网页块、电子邮箱 Email 地址、表情符号等文本中的特殊符号以及去重,只保留一对一和一对多的双语语料对应情况。

(2) 小写转换,标点规范化,分词与长度控制。

对所有俄语和英语数据进行小写转换。之后使用 Mosesdecoder 对所有语料文本进行标点符号的规范化处理。在分词方面,使用 Mosesdecoder 的 tokenizer 工具对英语文本进行分词,使用 python 分词工具 Natasha²对俄语文本进行分词,使用中科院系统开发的 urheen 对中文文本进行分词。文本中的长句和空句常常会引起训练过程中的问题,使用 Mosesdecoder 中的 clean-corpus 工具对文本中较长的语料进行清洗。控制文本长度在 1-150 之间,同时使用 NiuTrans 工具^[76]的 length_ratio_filter 方法进行长度比的过滤。长度比控制住 0.5-1.5 以内。

(3) 数据集划分。

使用 scikits.lean 工具^[77]中的 “model_selection.train_test_split” 方法在三种平行语料上进行训练集,开发集和测试集的划分。

(4) BPE 编码,词表生成与二进制转换。

在迁移学习的每一个训练阶段使用 subword_nmt³工具分别对训练的双语语料中每一种语言的训练数据进行基于字节对编码(BPE)算法^[78]的子词切分,BPE 编码大小为 32k。但在跨语言编码器的实验中需要对作为源语言的俄语和作为枢轴语言的英语进行联合 BPE 编码,编码大小也为 32k。词表生成与文件的二进制转换由 fairseq^[79]的数据预处理工具完成。

进行预处理后的数据规模如表 4.1 所示,其中微调阶段的数据有俄汉通用领域平行语料、俄汉科技文献标题平行语料和俄汉通用数据与俄汉标题数据的混合语料。测试集为 5 组人为翻译的俄汉科技文献标题平行语料。

表 4.1 预处理后语料规模

阶段	语料	数据规模(万)
预训练	俄英平行语料	2518
	英汉平行语料	1863
	俄汉通用领域平行数据	108
微调	俄汉科技文献标题平行数据	24
	俄汉通用+俄汉科技文献标题平行语料	132 (108+24)
测试集	俄汉科技文献标题测试集及五组译文集	0.2 (每组)

¹ <https://github.com/blmoistawinde/HarvestText>

² <https://github.com/natasha/natasha>

³ <https://github.com/rsennrich/subword-nmt>

4.3.2 实验设置

所有实验均在 CentOS Linux 服务器上进行, 使用 1-7 块 GPU 进行模型的训练, GPU 的 CUDA 版本为 11.7。Python 版本为 3.9.7, Pytorch 版本为 1.13.1。模型训练中的一些基本参数如表 4.2 所示。

表 4.2 基于枢轴词嵌入生成器的机器翻译模型实验设置

参数	含义	值
max_tokens	最大 token 数	4096
max_epoch	最大迭代次数	15
arch	模型框架参数	transformer
optimizer	优化器	adam
adam_betas	Adam 优化器 β_1 和 β_2 权重	(0.9, 0.997)
criterion	损失函数	label_smoothed_cross_entropy
label_smoothing	标签平滑	0.1
dropout	丢失率	0.3
lr	学习率	0.0007
warmup_init_lr	预热学习率初始值	1×10^{-7}
warmup_updates	预热学习率步长阈值	4000

在所有预训练模型的实验中, 所有模型的初始学习率都设置为 0.0001, 在模型训练至逐渐收敛, 用 0.00007 的学习率继续训练, 直至模型在验证集上的困惑度不再提升即停止训练。在枢轴词嵌入生成器的实验中, 在跨语言预训练模型基础上进行跨语言词嵌入生成器训练时, 使用 0.0001 的学习率继续训练, 训练 3epoch 即可。在冻结编码器信息训练解码器端参数阶段, 学习率的设定与其他预训练模型一样, 初始设置为 0.0001, 趋于收敛后设置为 0.00007。在源-目标语言模型的微调阶段, 一直保持用 0.0001 的学习率进行训练。

4.3.3 实验结果

整个实验共搭建 7 个基线系统, 分别是直接翻译 (Direct source-target), 利用两个预训练模型通过英语做枢轴语言的间接翻译 (Pivot translation), 基于枢轴语言的迁移学习 (Plain transfer), 以及分步训练策略的模型 (Stepwise train), 适配器策略模型 (Pivot adapter), 跨语言编码器策略模型 (Crosslingual encoder), 分步训练和跨语言编码器策略结合的模型 (Stepwise train+ Crosslingual encoder)。这 7 个基线模型用于和基于枢轴词嵌入生成器的模型 (Pivot embedding generator) 进行对比。本实验中模型的构建和词嵌入生成器的训练均在由 Meta 公司开发的序列建模工具 fairseq 上进行, 使用的 fairseq 版本为 0.10.2。Adapter 方法中

的枢轴适配器用 Meta 公司的 Muse 工具¹进行训练。

本章进行两组实验，第一组实验通过对比模型在不同微调数据上的效果，分析枢轴词嵌入生成器对低资源机器翻译效果的影响。第二组实验用来搭建最终的标题翻译模型，为第五章融合翻译打好基础。

在第一组实验中我们使用俄汉通用数据、俄汉科技文献标题数据对所有模型分别进行微调，两种微调数据的测试集和开发集分别为各自领域的的数据，其中标题数据微调的模型测试结果与本文构建的五组译文一起进行对比打分。表 4.3 为此组实验的所有结果。

表 4.3 基于枢轴词嵌入生成器的模型 Bleu4 打分

方法	通用数据 (bleu)	标题数据 (bleu)
Direct source-target	20.21	28.43
Pivot translation	21.73	24.51
Plain transfer	22.35	29.27
Pivot adaptor	23.62	29.52
Cross-lingual encoder	22.57	29.40
Step-wise pretrain	24.16	29.98
Cross-lingual encoder + step-wise pretrain	25.10	30.21
Pivot embedding generator based MT	26.74	33.35

从表 4.3 的结果来看，无论是科技文献标题数据上的打分还是俄汉通用数据上的打分，效果最差的是用源-目标语言直接训练的模型(Direct source-target)，这也说明了训练数据的规模深刻影响着模型效果。同时也印证着对低资源机器翻译引入与之相关的数据规模庞大的语料和预训练模型的必要性。枢轴翻译方法(Pivot translation)借用两个预训练模型搭建翻译系统，在通用数据上的打分要比直接训练的模型有所提高，但在标题数据上的打分反而效果变差，推测可能是因为标题数据中含有过多的专业术语，不经直接训练，通过间接翻译的方式翻不出来。这也向我们展示了间接翻译的局限性。5 个基于枢轴的迁移学习以及改进策略的模型通过参数迁移的手段使编码器和解码器分别继承两个预训练模型中的处理源语言信息和大规模目标语言信息的能力，通过微调的手段使模型更加适用于源-目标的机器翻译任务。无论是在标题数据还是通用数据上，直接迁移的模型效果要比直接训练的模型和经两次解码得到的模型效果都要提升很多，证明了基于枢轴的迁移学习方法(Plain transfer)可以有效提升模型性能。枢轴适配器(Pivot adapter)、跨语言编码器(Cross-lingual encoder)和分步训练的方

¹ <https://github.com/facebookresearch/MUSE>

法(Step-wise pretrain)是对基于枢轴的直接迁移方法的改进，可以用来解决参数迁移后的信息传递误差问题。它们与直接迁移学习的方法相比，在两个测试数据上的表现都有所提升。将分步训练和跨语言编码器策略相结合得出的模型效果在之前所有基线系统里效果最好的，在两个数据上的表现比基于直接迁移学习的模型分别高出 2.75 分和 0.94 分。本研究在这个方法(Step-wise pretrain+ Cross-lingual encoder)基础上融入跨语言词嵌入生成器和目标语言词嵌入生成器，在通用数据和标题数据上比分步训练和跨语言编码器结合的方法分别提升了 1.64 和 3.14 分。基于枢轴词嵌入生成器的方法（Pivot embedding generator based MT, PEG MT）在两种微调数据上都实现了翻译性能的提升，说明这种方法可以缓解基于枢轴语言迁移学习方法中信息传递误差现象缓解了词不匹配问题，能够有效提升低资源机器翻译效果。和通用领域微调数据相比，基于枢轴词嵌入生成器的方法在科技文献标题这种具有领域特征的数据上翻译性能提升幅度更大，说明当下游语料为领域内语料时，这种方法更加适用。因为对于下游领域中通用数据的词语，一般上游预训练词表中都已包含，翻译效果有所提升但并不明显。但对于领域语料这种含有较多未登陆词的数据，基于枢轴词嵌入生成器的模型对于未登陆词问题更有针对性，因此翻译性能提升幅度更大。所以本文构建的基于枢轴的机器翻译模型更能提升像标题这样具有领域词汇的文本的机器翻译效果。

第一组实验结果表明基于枢轴词嵌入生成器的机器翻译模型可以有效提升俄汉科技文献标题的机器翻译效果。为提升最终标题翻译效果，充分利用已有俄汉数据，我们进行第二组实验。我们将已有的俄汉通用领域数据和标题数据进行混合，在基于枢轴词嵌入生成器模型上共同训练最终的标题翻译模型。通用领域数据的加入在数据规模上可以直接推动标题翻译效果提升，同时其数据内容的广泛性也可以提升标题相关上下文的翻译效果，为第五章融合翻译打好基础。在构建最终标题机器翻译模型时，开发集我们以通用领域训练数据与标题训练数据的比例 5:2 进行混合构建，测试结果与本文构建的五组标题译文一起进行对比，使用 Bleu4 进行打分。最终的测试结果也将和第一组实验中的标题数据微调的枢轴词嵌入生成器模型对比。表 4.4 为实验结果。

表 4.4 基于枢轴词嵌入生成器的模型 Bleu 打分

	标题数据 (bleu4)	通用+标题数据 (bleu4)
Pivot embedding generator based MT	33.35	34.73

由表 4.4 实验结果可知，通用领域和标题数据混合而成的数据微调后的模型效果优于只使用标题数据微调的效果。因此在第五章，本文将已此模型作为

基础，研究标题的融合翻译。

4.4 小结

本章节对基于枢轴语言的迁移学习低资源机器翻译方法从迁移前后子词差异的角度进行了改进，将词嵌入生成器引入枢轴迁移学习网络，旨在细化子词粒度来增近编码器解码器信息传递，提出基于枢轴词嵌入生成器的机器翻译模型。从跨语言预训练，枢轴-目标预训练，枢轴词嵌入生成器三个方面介绍了基于枢轴词嵌入生成器的模型构建过程，最后实验验证了基于枢轴词嵌入生成器的翻译模型的效果，由实验结果可知，与其他强基线系统相比，基于枢轴词嵌入生成器的模型有效提升了科技文献标题的机器翻译效果，该俄汉机器翻译系统也为之后融合上下文信息的科技文献标题翻译奠定了基础。

5 融合上下文信息的科技文献标题的机器翻译

5.1 引言

在机器翻译任务中，准确地捕捉源语言句子的含义和上下文对于生成准确的目标语言翻译非常关键。本文研究对象为科技文献标题的俄汉机器翻译，俄语标题属于短文本，文字表达不充分导致神经机器翻译模型无法感知到足够的语义信息；科技文献标题中含有不少俄语专业词汇，缺乏领域上下文信息来辅助标题中这些专业词汇的翻译。因此科技文献标题的俄汉机器翻译效果一直不理想。

为了解决上述问题，本章从上下文信息辅助标题机器翻译角度入手，提出融合上下文信息的科技文献标题的机器翻译模型。此模型采用上下文感知（Context-aware）机制^[80]，当标题翻译模型在对源语言进行解码时，将上下文句子的信息经上下文编码器编码表示后和源语言标题的编码表示通过不同融合策略一同融入标题翻译模型的解码器，促使其在进行源语言标题的解码时可以考虑其上下文信息，从而生成更准确的标题译文。在整个上下文感知机制中，标题的上下文信息既可以是源语言的上下文，也可以是目标语言的上下文。

5.2 模型

图5.1为本章融合上下文信息的科技文献标题的机器翻译模型的构建流程。整个流程分为上下文信息和融合模型两部分。首先是上下文信息部分，标题的上下文信息可以是多种类型，其中摘要信息由标题上下文抽取模型获得，标题信息直接由输入的源句子获得，涉及到的译文信息由本文第四章构建的基于枢轴词嵌入生成器的俄汉机器翻译模型获得。之后是融合模型，其结构由标题编码器、标题解码器、上下文编码器、融合策略四部分组成。其中标题解码器用来对源语言标题句子进行编码，上下文编码器用来对上下文信息进行编码，融合策略指对两个编码器得到的信息做融合表示，之后用标题解码器对这个综合了源句子和上下文信息的表示做解码，最后输出经融合翻译后的标题译文。其中标题编码器和标题解码器在训练时由本文第四章构建的基于枢轴词嵌入生成器的俄汉机器翻译模型进行参数初始化来为其提供良好的起点。




图 5.1 融合翻译模型构建流程

5.2.1 上下文信息

在融合翻译模型中上下文信息对机器翻译的效果起着非常重要的影响。好的上下文信息可以使原文翻译的更加流畅准确，不好的上下文信息会损害原有翻译效果。标题上下文信息有时可以是语境式描述性的一段话，例如摘要；有时其自身就可以做上下文信息，多编码器只对标题自身简短的文本编码就可充分发掘其内在语义。因此本节分别从摘要和标题两个内容方向构建多种上下文信息，在后续实验探究何种上下文信息更有益于标题的融合翻译。

表 5.1 摘要内容作为上下文

序号	内容	来源
①	摘要	上下文抽取
②	摘要句 sim top1	上下文抽取+BM25 相似度计算
③	摘要句 sim top2	上下文抽取+BM25 相似度计算
④	摘要句 sim top3	上下文抽取+BM25 相似度计算
⑤	摘要译文	上下文抽取+PEG MT
⑥	摘要句 sim top1 译文	上下文抽取+BM25 相似度计算+ PEG MT
⑦	摘要句 sim top2 译文	上下文抽取+BM25 相似度计算+ PEG MT
⑧	摘要句 sim top3 译文	上下文抽取+BM25 相似度计算+ PEG MT

如表 5.1 所示，本文从摘要这种语境式的上下文出发，设计多个与摘要相

关的上下文信息。表中内容为俄语摘要的上下文信息由第三章上下文抽取模型获得。汉语摘要信息为它经过第四章基于枢轴词嵌入生成器俄汉翻译模型翻译后的译文。对于科技文献摘要这样的上下文信息，它的文本长度较长，整个一段话中可能只有个别句话与标题内容最为相关。因此文本采用 BM25 算法^[81]对生成的摘要中的每句话与标题进行相似度对比，选取相似度最高的几句话作为标题的上下文信息。

表 5.2 标题作为上下文

序号	内容	来源
①	标题	标题自身
②	标题译文	PEG MT
④	相似标题	大模型生成相似标题
⑤	相似标题译文	大模型生成相似标题+PEG MT

如表 5.2 所示，除标题自身文本和译文外，我们使用指令 “please give a similar title.” 让大模型生成类似标题，并将其翻译为汉语。将这四种类型标题信息作为标题类的上下文信息。

5.2.2 融合模型

融合上下文信息的标题机器翻译模型实质是个融合模型，是对标题翻译结果的进一步改进，通过获取标题的上下文信息并对其采用编码器结构嵌入神经网络中来提升标题的翻译效果。

融合上下文信息的标题翻译模型是一个含有多个编码器的结构，其中除了有对源语言的标题进行编码的编码器，针对上下文信息也有特定的编码器，因此针对输入的上下文信息 c ，会有上下文编码器负责对上下文文本进行上下文建模，输出隐层状态 h_c ，为之后的上下文信息融合奠定基础。

本文第四章构建的基于枢轴词嵌入生成器的俄汉机器翻译对于俄语标题的翻译能力很强。因此融合模型中将基于枢轴词嵌入生成器的俄汉机器翻译模型参数迁移到融合模型中的源语言标题编码器和目标语言标题的解码器上，为融合上下文信息的训练提供一个好的起点。在迁移过程中，由于基于枢轴词嵌入生成器的俄汉翻译模型继承了两个预训练模型的词表，其词表覆盖率高，因此翻译模型中也继承了基于枢轴词嵌入生成器俄汉翻译模型的词表。

根据多编码器融合上下文系统的两种融合方法，本章构建两种融合上下文信息的标题机器翻译模型。分别是对上下文信息进行外部融合的标题翻译模型和对上下文信息进行外部融合的标题翻译模型，以下为对它们两者的介绍。




图 5.2 对上下文信息进行外部融合的头标题翻译模型

对上下文信息进行外部融合的头标题翻译原理如图 5.2 所示，该模型采用多编码器（Multi Encoder）结构，在原 Transformer 标题翻译模型的基础上，增加上下文编码器 Encoder_C，对上下文信息进行上下文建模，通过编码分别得到隐层状态 H_C ，它和源语言句子经过编码器 Encoder_S 得到的隐层状态 H_S 通过 Attention 注意力网络模块进行信息融合，形成隐层状态 H_C' ，如公式 5.1 所示。在门控机制的作用下， H_S 和 H_C' 进一步被整合，形成最终的融合表示信息 H_{fusion} ，如公式 5.2 所示。之后，隐层表示信息 H_{fusion} 被输入到解码器端的编码-解码注意力网络中，参与模型解码过程。

$$H_C' = \text{MultiHeadAttention}(H_S, H_C) \tag{公式 5.1}$$

$$H_{fusion} = \lambda_t H_S + (1 - \lambda_t) H_C' \tag{公式 5.2}$$




图 5.3 对上下文信息进行内部融合的标题翻译模型

对上下文信息进行内部融合的标题翻译原理如图 5.3 所示，源语言当前句子经过编码器 Encoder_S 和解码器端的 Attention_S 注意力网络模块形成隐层状态 H_S' ；上下文句子通过上下文编码器 Encoder_C 生成隐层状态 H_C ， H_C 在解码阶段通过 Attention_C 注意力网络模块计算生成隐层状态 $H_{C'}$ ，如公式 5.3 所示。 H_S' 和 $H_{C'}$ 通过门控机制形成最终的融合表示信息 H_{fusion} ，如公式 5.4 所示。该信息经过解码器中其他模块的进一步转换，最终完成模型解码。

$$H_{C'} = \text{MultiHeadAttention}(H_C) \tag{公式 5.3}$$

$$H_{fusion} = \lambda_t H_S' + (1 - \lambda_t) H_{C'} \tag{公式 5.4}$$

5.3 实验

本章在科技文献标题数据上进行俄语到汉语的标题机器翻译实验，探究融合的翻译方法的有效性，实验使用大小写不敏感的 BLEU-4 作为评价指标。

5.3.1 实验数据

本章实验使用的标题数据为 24 万的俄汉科技文献的标题数据，与第四章标题的测试集数据相同。对于实验用到的上下文信息数据，第 5.2.1 小节已经给出数据来源。所有的数据预处理过程与第四章预处理过程保持一致。

5.3.2 实验设置

所有实验均在 CentOS Linux 服务器上进行，使用 1-7 块 GPU 进行模型的训练，GPU 的 CUDA 版本为 11.7。Python 版本为 3.9.7，Pytorch 版本为 1.13.1。本章依据上下文信息和融合策略的不同进行多个实验。所有实验中模型的构建均在由 Meta 公司开发的序列建模工具 fairseq 上进行，使用的 fairseq 版本为 0.9.0。模型训练中的一些基本参数如表 5.3 所示。

表 5.3 实验设置

参数	含义	值
max_tokens	最大 token 数	4096
arch	模型框架参数	transformer
optimizer	优化器	adam
adam_betas	Adam 优化器 β_1 和 β_2 权重	(0.9, 0.997)
criterion	损失函数	label_smoothed_cross_entropy
label_smoothing	标签平滑	0.1
dropout	丢失率	0.3
lr	学习率	0.0001
warmup_init_lr	预热学习率初始值	1×10^{-7}
warmup_updates	预热学习率步长阈值	4000

5.3.3 实验结果

依据上下文信息和融合策略的不同，对融合上下文信息的标题翻译进行实验验证。

首先对融合上下文信息和不融合上下文信息的标题翻译进行实验。前者只使用标题数据进行训练，使用两个模型进行对比，一是使用标题数据直接训练的 Transformer 模型，二是使用第四章训练好的基于枢轴词嵌入生成器的俄汉翻译模型。后者融合的上下文信息分别为摘要、摘要译文、标题和标题译文。实验结果如表 5.4 所示。

表 5.4 融合上下文信息的标题翻译结果

上下文信息	外部融合	内部融合
无	28.43（直接训练）	28.43（直接训练）
无	34.73（PEG MT）	34.73（PEG MT）
标题	35.14	35.25
标题译文	35.42	35.33
摘要	35.86	35.77

摘要译文	35.91	35.95
------	-------	-------

如表 5.4 实验结果可知：对于不融合上下文信息的模型来说，本文构建的基于枢轴词嵌入生成器的俄汉翻译模型对于标题数据直接训练的模型质量提升幅度很大，说明了将第四章俄汉翻译模型对标题融合翻译进行参数初始化可以为标题翻译提供良好的起点。不管融合的上下文信息是摘要还是标题，标题机器翻译效果相较于不融合上下文的翻译效果都要好，至少提升 0.4 分以上。其中融合摘要类上下文信息标题翻译效果要优于融合标题类的上下文信息，融合译文的标题翻译效果优于融合源语言的上下文。融合译文信息内部或外部的融合策略对标题翻译效果影响不大。摘要译文作为上下文信息的标题翻译效果最好，达到了 35.95 分，比不融合上下文信息的标题翻译效果高出了 1.22 分。

对标题类上下文信息进行标题融合机器翻译实验，融合的上下文信息除了标题及其译文，还有相似标题和译文。结果如表 5.5 所示。

表 5.5 融合标题类上下文信息的标题翻译结果

实验	上下文信息	外部融合	内部融合
融合标题类	标题	35.14	35.25
	标题译文	35.42	35.33
	相似标题	34.77	34.31
	相似标题译文	34.86	34.91

如表 5.5 实验结果可知，标题类信息作为上下文时，融合译文标题作为上下文的标题翻译效果都要优于融合标题自身的。其中，融合相似标题的翻译效果不如融合真实标题的翻译效果。

对摘要类上下文信息进行标题融合机器翻译实验，融合的上下文信息除了摘要及其译文，还有从摘要中和标题最为相似的前三个句子及其译文。结果如表 5.6 所示。

表 5.6 融合摘要类上下文信息的标题翻译结果

实验	上下文信息	外部融合	内部融合
融合摘要类	摘要	35.86	35.77
	摘要句 sim top1	34.65	34.69
	摘要句 sim top2	34.55	34.45
	摘要句 sim top3	33.90	33.76

摘要译文	35.91	35.95
摘要句 sim top1	34.80	34.77
摘要句 sim top2	34.59	34.67
摘要句 sim top3	34.33	34.38

如表 5.6 实验结果可知，使用摘要中与标题最为相似的三句话作为上下文时，融合越相似的句子做上下文，标题的翻译效果越好。说明与标题越相似，其上下文相关性越大。但总体来说，融合摘要中个别句子的上下文信息依旧与融合整个摘要的上下文信息的机器翻译效果有差距。因此从本章的实验结果来看，将摘要作为上下文信息，融合到标题机器翻译的方法是有效的，可以用来提升标题的翻译质量。

6 总结与展望

6.1 总结

本文提出了融合标题上下文信息的科技文献标题机器翻译研究方法，从标题上下文获取和俄汉低资源机器翻译提升，标题机器翻译提升三个方面对研究工作进行了总结：

(1) 标题上下文抽取。

本文将摘要信息作为标题的上下文，构建了已有论文库检索，Web 上下文检索和大模型生成的三种路径标题上下文信息获取路径。其中大模型生成机制采用大模型微调技术进行模型训练，可以充分利用大模型广泛的知识来辅助摘要生成技术。本文构建的标题上下文获取机制可以获取与标题上下文极为关联的类似摘要的信息的能力。

(2) 俄汉低资源机器翻译质量提升。

针对俄汉科技文献机器翻译质量的提升，本文先提出了基于枢轴词嵌入生成器的俄汉翻译模型，在基于枢轴的迁移过程引入枢轴词嵌入生成器，通过枢轴词嵌入生成器在原词表基础上生成大量新词嵌入来弥补微调时的子词差距，提升模型的鲁棒性和开放性。本文构建的基于枢轴词嵌入生成器的低资源机器翻译模型可以有效提升低资源机器翻译水平。

(3) 标题机器翻译提升。

针对标题翻译性能不佳的问题，本文建立融合上下文信息的标题机器翻译模型，通过多编码器策略将标题的上下文信息与标题信息进行融合，使模型能够根据上下文信息充分理解标题含义，使解码器进行更有效的解码，从而生成更好的译文。本文构建的融合上下文信息的标题机器翻译模型可以提升标题翻译的准确性。

6.2 展望

本研究还存在一些不足之处，需要进一步开展后续研究：

(1) 大模型不稳定性。

在大模型生成摘要的获取路径中，其生成能力仍然受限于训练数据和模型的容量。在处理复杂语境时，大模型可能无法完全捕捉到所有重要的上下文信息，导致一些信息丢失或混淆。融合标题上下文的模型在生成翻译结果时高度依赖于上下文信息。这意味着如果上下文信息不完整、不准确或存在歧义，模

型的性能可能会受到影响。此外，模型对上下文信息的过度依赖可能导致对输入中的错误或噪声过度敏感影响翻译性能。后续可以增加错误字符和噪音过滤机制，并调节大模型的参数增加模型的稳定性

（2）低资源机器翻译问题。

除本文提出的基于枢轴词嵌入生成器的方法外，还存在其他改进枢轴迁移学习中信息传递误差的方法，今后研究将针对低资源机器翻译问题做进一步探索。

参考文献

- [1] 编辑出版学名词审定委员会. 编辑与出版学名词[M]. 北京:科学出版社,2022:21.
- [2] 《陕西气象》编辑部. 科技论文标题的拟定[J]. 陕西气象,2019(5):66-67.
- [3] PHILIPP K,FRANZ J O,DANIEL M. Statistical phrase-based translation[C]. Proceedings of the 2003 Human Language Technology Conference of the North American Chapter of the Association for Computational Linguistics. Stroudsburg:Association for Computational Linguistics,2003:48-54.
- [4] ASHISH V,NOAM S,NIKI P,et al. Attention is all you need[C]. Proceedings of the 31st International Conference on Neural Information Processing Systems. New York:Curran Associates Inc,2017:6000-6010.
- [5] 冯志伟. 基于短语和句法的统计机器翻译[J]. 燕山大学学报,2015,39(6):546-554,560.
- [6] 李亚超,熊德意,张民. 神经机器翻译综述[J]. 计算机学报,2018,41(12):100-121.
- [7] YU W,BAOSONG Y,DEREK F W,et al. Challenges of neural machine translation for short texts[J]. Computational Linguistics,2022,48(2):321-342.
- [8] 张利新. 论科技文献标题的翻译[J]. 沈阳航空工业学院学报,2006,23(6):170-172.
- [9] 肖桐,朱靖波. 机器翻译:基础与模型[M]. 北京:电子工业出版社, 2021:517-518.
- [10] ALEC R,KAR N,TIM S. Improving language understanding by generative pretraining[EB/OL]. (2018-6-11)[2023-10-23].https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf.
- [11] CHIN L. Rouge: a package for automatic evaluation of summaries[C]. Proceedings of the 2004 ACL Workshop on Text Summarization Branches Out. Barcelona:Association for Computational Linguistics,2004:74-81.
- [12] KISHORE P,SALIM R,TODD W, et al. Bleu:a method for automatic evaluation of machine translation[C]. Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics. Philadelphia:Association for Computational Linguistics,2002:311-318.
- [13] PENGFEI L,WEIZHE Y,JINLAN F,et al. Pre-train,prompt,and predict:a systematic survey of prompting methods in natural language processing[J]. ACM Computing Surveys,2023:55(9):35.

- [14] PETER F,STEPHEN H,VINCENT J,et al. The mathematics of statistical machine translation:parameter estimation[J]. Computational Linguistics, 1993,19(2):263-311.
- [15] 熊德意,刘群,林守勋. 基于句法的统计机器翻译综述[J].中文信息学报, 2008, 22(2):12.
- [16] NAL K,PHIL B. Recurrent continuous translation models[C]. Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing. Seattle:Association for Computational Linguistics,2013:1700-1709.
- [17] ILYA S, ORIOL V, QUOC V. Sequence to sequence learning with neural networks[C]. Proceedings of the 27th International Conference on Neural Information Processing Systems. Cambridge:MIT Press,2014:3104-3112.
- [18] KYUNGHYUN C,BART M,CAGLAR G,et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Doha:Association for Computational Linguistics,2014:1724-1734.
- [19] DZMITRY B,KYUNG H,YOSHUA B. Neural machine traslation by jointly learning to align and translate[C]. The 3rd International Conference on Learning Representations. San Diego:OpenReview,2015:102-108.
- [20] Thang L,Hieu P,Christopher D. Effective approaches to attention-based neural machine translation[C]. Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. Portugal:Association for Computational Linguistics,2015: 1412-1421.
- [21] BA J,KIROS J,HINTON G. Layer normalization[EB/OL]. (2016-12-10)[2023-07-20]. <https://doi.org/10.48550/arXiv.1607.06450>.
- [22] HE K,ZHANG X,REN S,et al. Deep residual learning for image recognition[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE,2016:770-778.
- [23] 刘洋. 神经机器翻译前沿进展[J]. 计算机研究与发展,2017,54(6):1144-1149.
- [24] KYUNGHYUN C,BART V,DZMITRY B,et al. On the properties of neural machine translation: encoder-decoder approaches[C]. Proceedings of Eighth Workshop on Syntax, Semantics and Structure in Statistical Translation. Doha:Association for Computational Linguistics,2014:103-111.
- [25] ANTONIO T,VICTOR M. A multifaceted evaluation of neural versus phrase-based machine translation for 9 language directions[C]. Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics. Valencia:Association for Computational Linguistics,2017:1063-1073.

- [26] MASATO N,NAOKI Y. On the relation between position information and sentence length in neural machine translation[C]. Proceedings of the 23rd Conference on Computational Natural Language Learning. Hong Kong: Association for Computational Linguistics,2019:328-338.
- [27] YANG ZHAO, LU XIANG, JUNNAN ZHU,et al. Knowledge graph enhanced neural machine translation via multi-task learning on sub-entity granularity[C]. Proceedings of the 28th International Conference on Computational Linguistics.Barcelona: International Committee on Computational Linguistics,2020: 4495-4505.
- [28] BARRET Z,DENIZ Y,JONATHAN M,et al. Transfer learning for low-resource neural machine translation[C]. Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. Austin:Association for Computational Linguistics,2016:1568-1575.
- [29] TOAN N,DAVID C. Transfer learning across low-resource, related languages for neural machine translation[C]. Proceedings of the Eighth International Joint Conference on Natural Language Processing. Taipei:Asian Federation of Natural Language Processing,2017: 296-301.
- [30] JIATAO G,YONG W,YUN C,et al. Meta-learning for low-resource neural machine translation[C]. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels: Association for Computational Linguistics,2018:3622-3631.
- [31] RAJ D,ATSUSHI F,CHENHUI C. Exploiting multilingualism through multistage fine-tuning for low-resource neural machine translation[C]. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Hong Kong:Association for Computational Linguistics,2019:1410-1416.
- [32] YUNSU K,PETRE P,PAVEL P,et al. Pivot-based transfer learning for neural machine translation between non-english languages[C]. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing. Hong Kong:Association for Computational Linguistics,2019:866-876.
- [33] YICHAO L, PHILLIP K, FAISAL L,et al. A neural interlingua for multilingual machine translation[C]. Proceedings of the Third Conference on Machine Translation:Research Papers. Brussels:Association for Computational Linguistics,2018:84-92.
- [34] CHAO X, DONG W, CHAO L,et al. Normalized word embedding and orthogonal transform for bilingual word translation[C]. Proceedings of the 2015 Conference of the North American Chapter of the Association for

Computational Linguistics:Human Language Technologies.

Denver:Association for Computational Linguistics,2015:1006-1011.

- [35] RICO S,BARRY H,ALEXANDRA B. Neural machine translation of rare words with subword units[C]. Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics. Berlin:Association for Computational Linguistics,2016:1715-1725.
- [36] MENG Z,LIANGYOU L,QUN L. Triangular transfer: freezing the pivot for triangular machine translation[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Dublin:Association for Computational Linguistics,2022: 644-650.
- [37] DABRE R,CHU C, KUNCHUKUTTAN A. A comprehensive survey of multilingual neural machine translation[J]. ACM Computing Surveys, 2020,53(5):1557-7341.
- [38] 黎家全,王丽清,李鹏,等.面向神经机器翻译的枢轴方法研究综述[J].计算机工程与应用, 2022, 58(16):7.
- [39] MELVIN J,MIKE S, QUOC V. Google's multilingual neural machine translation system: enabling zero-shot translation[J]. Transactions of the Association for Computational Linguistics,2017,32(5):339-351.
- [40] MARUAN A, ANKUR P. Consistency by agreement in zero-shot neural machine translation[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Minneapolis:Association for Computational Linguistics,2019: 1184-1197.
- [41] MAIMAITI M,LIU Y, LUAN H,et al. Multi-round transfer learning for low-resource mmt using multiple high-resource languages[J]. ACM Transactions on Asian and Low-Resource Language Information Processing,2019,24(6),1-26.
- [42] 于新松. 科技论文标题翻译技巧与方法[J]. 海外英语(上),2021(4):19-20.
- [43] 邵建国. 规则与实例相结合的公文标题汉英机器翻译系统[J]. 办公自动化(综合版),2010(1):36-38.
- [44] 苗洪霞,蔡东风,宋彦,等. 利用统计机器翻译方法实现航空领域标题的翻译[J]. 通讯和计算机,2007,004 (2):75-78.
- [45] 杨沐昀,石振勇,朱俊国,等. 基于 WEB 检索的论文标题译文获取[C]. 第六届全国信息检索学术会议. 哈尔滨:中文信息学会,2010:367-374.
- [46] NIKOLAY B,WALTER D,MIKE K. Neural machine translation of artwork titles using iconclass codes[C]. Proceedings of the The 4th Joint SIGHUM Workshop on Computational Linguistics for Cultural Heritage, Social Sciences, Humanities and Literature. Online:International Committee on Computational Linguistics,2020:42-51.

- [47] 车万翔,郭江,崔一鸣. 自然语言处理:基于预训练模型的方法[M]. 北京:电子工业出版社, 2021:379-381.
- [48] SHUMWAY R H , STOFFER D S.Time series analysis and its applications (Springer Texts in Statistics)[M]. New York:Springer-Verlag New York, Inc. 2005:254-257.
- [49] KAUSHIK P,GAIN A,KORTYLEWSKI A,et al.Understanding catastrophic forgetting and remembering in continual learning with optimal relevance mapping[EB/OL]. (2021-6-11)[2023-10-23]. DOI:10.48550/arXiv.1703.08475.
- [50] BEI L,HUI L,ZIYANG W,et al. Does multi-encoder help? a case study on context-aware neural machine translation[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online:Association for Computational Linguistics,2020:3512-3518.
- [51] JIACHENG Z, HUANBO L, MAOSONG S,et al. Improving the transformer translation model with document-level context[C]. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels: Association for Computational Linguistics,2018: 533-542.
- [52] ELENA V, PAVEL S, RICO S,et al. Context-Aware neural machine translation learns anaphora resolution[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. Melbourne: Association for Computational Linguistics,2018: 1264-1274.
- [53] WANG S,ZHOU W,JIANG C. A survey of word embeddings based on deep learning[J].Computing, 2020,102(3):717-740.
- [54] BOTH A J A,BLUNSOM P. Compositional morphology for word representations and language modelling[C]. Proceedings of the 31st International Conference on International Conference on Machine Learning. Beijing:JMLR.org,2014: 1899-1907.
- [55] THANG L,RICHARD S,CHRISTOPHER M. Better word representations with recursive neural networks for morphology[C]. Proceedings of the Seventeenth Conference on Computational Natural Language Learning. Sofia:Association for Computational Linguistics,2013:104-113.
- [56] PARMINDER B,ROBERT G,JACOB E. Morphological priors for probabilistic neural word embeddings[C]. Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. Austin:Association for Computational Linguistics,2016: 490-500.
- [57] KIM Y,JERNITE Y,SONTAG D,et al. Character-aware neural language models[C]. National Conference on Artificial Intelligence. Phoenix: AAAI press,2016:.
- [58] JOHN W,MOHIT B,KEVIN G,et al. Charagram: embedding words and sentences via character n-grams[C]. Proceedings of the 2016 Conference on

Empirical Methods in Natural Language Processing. Austin:Association for Computational Linguistics,2016:1504-1515.

- [59] SANTOS D,ZADROZNY B. Learning character-level representations for part-of-speech tagging[C]. International Conference on Machine Learning. Beijing:JMLR.org,2014:1818-1826.
- [60] BARBARA P,ANDERS S,YOAV G. Multilingual part-of-speech tagging with bidirectional long short-term memory models and auxiliary loss[C]. Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics.Berlin:Association for Computational Linguistics,2016: 412-418.
- [61] YUVAL P,ROBERT G,JACOB E. Mimicking word embeddings using subword rnns[C]. Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Copenhagen:Association for Computational Linguistics,2017:102-112.
- [62] PENG Z, WEI S, JUN T,et al. Attention-based bidirectional long short-term memory networks for relation classification[C]. Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics. Berlin:Association for Computational Linguistics,2016:207-212.
- [63] PIOTR B, EDOUARD G, ARMAND J. Enriching word vectors with subword information[J]. Transactions of the Association for Computational Linguistics. 2017,5:135-146.
- [64] JINMAN Z,SIDHARTH M, YINGYU L. Generalizing word embeddings using bag of subwords[C]. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels:Association for Computational Linguistics,2018:601-606.
- [65] SHOTA S, JUN S,KENTARO I. Subword-based compact reconstruction of word embeddings[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Minneapolis:Association for Computational Linguistics,2019:3498-3508.
- [66] XIN L, BAOSONG Y, DAYIHENG L,et al. Bridging subword gaps in pretrain-finetune paradigm for natural language generation[C]. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. Online:Association for Computational Linguistics,2021: 6001-6011.
- [67] HINTON G ,VINYALS O,DEAN J. Distilling the knowledge in a neural network [J]. Computer Science,2015,14(7):38-39.
- [68] BOUAMRANE K,MATALLAH H,BELALEM G. Comparative study between the mysql relational database and the mongodb nosql database[J]. International journal of software science and computational intelligence, 2021,52(3):13.

- [69] TIMO S,HINRICH S. Exploiting cloze-questions for few-shot text classification and natural language inference[C]. Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics. Online:Association for Computational Linguistics,2021:255-269.
- [70] ZHENGXIAO D,YUJIE Q,XIAO L,et al. GLM:general language model pretraining with autoregressive blank infilling[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Dublin: Association for Computational Linguistics,2022:320-335.
- [71] LIU X,JI K,FU Y,et al. P-Tuning v2:prompt tuning can be comparable to fine-tuning universally across scales and tasks[EB/OL]. (2022-7-11)[2023-10-23]. <https://doi.org/10.48550/arXiv.2110.07602>.
- [72] 李舟军,范宇,吴贤杰. 面向自然语言处理的预训练技术研究综述[J]. 计算机科学,2020,47(3):162-173.
- [73] VINCENT P ,LAROCHELLE H,BENGIO Y,et al. Extracting and composing robust features with denoising autoencoders[C]. Proceedings of the 25th international conference on Machine learning. Helsinki: Association for Computing Machinery,2008:1096-1103.
- [74] Felix H,Kyunghyun C,Anna K. Learning distributed representations of sentences from unlabelled data[C]. Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. San Diego:Association for Computational Linguistics,2016:1367-1377.
- [75] SERGEY E,MYLE O,MICHAEL A,et al. Understanding back-translation at Scale[C]. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels:Association for Computational Linguistics,2018: 489-500.
- [76] 肖桐,张浩,李强,等. NiuTrans:开源统计机器翻译系统[J]. 程序员, 2012(8):4.
- [77] SWAMI A ,JAIN R. Scikit-learn: machine learning in python[J]. Journal of Machine Learning Research,2013,12(10):2825-2830.
- [78] RICO S,BARRY H,ALEXANDRA B. Neural machine translation of rare words with subword units[C]. Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics. Berlin: Association for Computational Linguistics,2016:1715-1725.
- [79] MYLE O,SERGEY E,ALEXEI B, et al. Fairseq: a fast, extensible toolkit for sequence modeling[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics. Minneapolis: Association for Computational Linguistics, 2019: 48-53.

- [80] JORG T, YVES S. Neural machine translation with extended context[C]. Proceedings of the Third Workshop on Discourse in Machine Translation. Copenhagen: Association for Computational Linguistics, 2017: 82-92.
- [81] ROBERTSON S,ZARAGOZA H,ROBERTSON S,et al.The probabilistic relevance framework: bm25 and beyond[J]. Foundations and Trends in Information Retrieval,2009,3(4):333-389.

作者简介

姓名：郭姝澳

性别：女

民族：汉

出生年月：1999-07

籍贯：河南省新乡市

教育经历

2017.09—2021.06	河南工业大学	自动化	学士
2021.09—2024.01	中国科学技术信息研究所	竞争情报	硕士

项目经历

[1] 中国科学技术信息研究所重点工作项目“基于全文科技文献的跨语言知识发现研究”（项目编号：ZD2021-17）

[2] 中国科学技术信息研究所重点工作项目“面向短文本的俄汉双向机器翻译研究”（项目编号：ZD2022-20）

[3] 中国科学技术信息研究所重点工作项目“智能情报融合创新体系建设研究与应用”（项目编号：ZD2023-11）

攻读硕士学位期间发表的学术论文

[1] GUO S A, GUO H C, HE Y Q, et al. Istic's thai-to-chinese neural machine translation system for ccmt' 2022[C]. The Eighteenth China Conference on Machine Translation. Singapore:Springer,2022:151-160.

[2] **GUO S A, DENG N Y, HE Y Q.** Istic's neural machine translation systems for ccmt' 2023[C]. The Nineteenth China Conference on Machine Translation. Singapore:Springer,2023:94-102.

[3] **Deng N Y, Guo S A, He Y Q.** Istic neural machine translation system for evahan 2023[C]. Proceedings of ALT2023: Ancient Language Translation Workshop. Macau SAR: Asia-Pacific Association for Machine Translation,2023:34-42.

学位论文数据集

关键词*	密级*	中图分类号*	UDC	论文资助
低资源机器翻译；迁移学习；词嵌入生成器；大语言模型；上下文融合	公开	G350.7/TP391.2	004	
学位授予单位名称*	学位授予单位代码*	学位类别*	学位级别*	
中国科学技术信息研究所	80901	管理学	硕士	
论文题名*	并列题名*			论文语种*
融合上下文信息的科技文献标题的机器翻译	Research on Machine Translation for Titles of Scientific Papers with Contextual Information			中文
作者姓名*	郭姝澳	学号*	809012132	
培养单位名称*	培养单位代码*	培养单位地址	邮编	
中国科学技术信息研究所	80901	北京市海淀区复兴路15号	100038	
学科专业*	研究方向*	学制*	学位授予年*	
竞争情报	技术竞争情报	2.5年	2024年	
论文提交日期*	2023年10月			
导师姓名*	董诚	职称*	研究员	
导师姓名*	何彦青	职称*	研究员	
评阅人	答辩委员会主席*	答辩委员会成员		
	马婷婷	王桂玲, 刘志辉, 张晓丹, 陈亮		
电子版论文提交格式 文本 (√) 图像 () 视频 () 音频 () 多媒体 () 其它 () 推荐格式: application/msword; application/pdf				
电子版论文出版 (发布) 者	电子版论文出版 (发布) 地	权限声明		
论文总页数*	79			
共 33 项, 其中带*为必填数据, 为 22 项。				